

# Capítulo 1

## Probabilidade

**Objetivo:** Definir um modelo estatístico que seja adequado à descrição e interpretação de fenômenos aleatórios.

### 1.0.1 Conceitos básicos

**Experimentos ou fenômenos aleatórios ( $\varepsilon$ )** : são os acontecimentos cujos resultados não podem ser previstos com certeza, sob condições idênticas.

**Exemplos :**

- Lançamento de um dado.
- Lançamento de uma moeda.
- Tempo de vida útil de um componente eletrônico.

**Espaço Amostral ( $\Omega$ ):** refere-se ao conjunto de todos os possíveis resultados de um experimento ou fenômeno aleatório.

**Exemplos :**

$$\Omega_1 = \{1, 2, 3, 5, 6\}$$

$$\Omega_2 = \{c, k\} \text{ Sendo } k \text{ cara, } c \text{ coroa.}$$

$$\Omega_3 = [0, \infty\}$$

**Evento:** qualquer subconjunto do espaço amostral  $\Omega$  do experimento aleatório  $\varepsilon$ .

**Notação:**  $A, B, C, D, \dots, A_1, A_2, A_3, \dots, B_1, B_2, \dots$

Notamos que, como  $A$  é um evento então  $A \subset \Omega$ .

### 1.0.2 Tipos de Eventos

**Evento Simples ou Elementar:** é o evento formado por um único ponto do espaço amostral.

**Exemplo:**  $A = \{w\}$ .

**Evento Composto:** é o evento formado por dois ou mais pontos do espaço amostral.

**Exemplo:**  $A = \{w_1, w_2, w_3\}$

**Evento Certo:** é o evento formado por todos os pontos amostrais.

**Exemplo :**  $A = \Omega$

**Evento Impossível :** É o evento que não possui elementos de  $\Omega$ , isto é, evento vazio.

**Notação :**  $A = \{\}$  ou  $A = \emptyset$

**Alguns Exemplos :**

$A$  = Face do dado maior que 5.

$A = \{6\}$

$B$  = Face do dado ser par.

$B = \{2, 4, 6\}$

$C$  = Face do dado maior ou igual a 1.

$C = \{1, 2, 3, 4, 5, 6\} = \Omega$

$D$  = Face do dado maior que 6.

$D = \{\}$  ou  $D = \emptyset$

### 1.0.3 Operação com Eventos

Para ilustrar graficamente eventos é costume utilizar-se dos mesmos diagramas de Venn utilizados na teoria de conjuntos.

Considere eventos definidos em um espaço amostral  $\Omega$  de um experimento aleatório  $\varepsilon$ .

**União de eventos ( $A \cup B$ ) :** é o evento formado por todos os elementos que pertencem a  $A$ , ou  $B$ , ou ambos.




Figura 1.1:

**Intersecção de eventos ( $A \cap B$ ) :** é o evento formado pelos elementos que pertencem a  $A$  e a  $B$ .




Figura 1.2:

**Casos Particulares :**

1. Se  $B \subset A$ , então  $A \cap B = B$




Figura 1.3:

2. Se  $A$  e  $B$  são eventos disjuntos ou mutuamente exclusivos (não possui elementos comuns), então  $A \cap B = \emptyset$ .




Figura 1.4:

**Diferença de eventos ( $A - B$ ) :** é o evento formado pelos elementos que pertencem a  $A$  mas não pertencem a  $B$ .




Figura 1.5:

**Evento Complementar ( $\bar{A}$  ou  $A^c$ ) :** é o evento formado por todos os elementos de  $\Omega$  que não pertencem a  $A$ .




Figura 1.6:

**Alguns exemplos de eventos complementares :**

(a)  $(A \cup B)^c = A^c \cap B^c$




Figura 1.7:

(b)  $(A \cap B)^c = A^c \cup B^c$




Figura 1.8:

Os itens (a) e (b) são conhecidos como Lei de Demorgan.

(c)  $A \cup B^c = (A \cap B) \cup B^c = A \cup (A \cup B)^c$




Figura 1.9:

(d)  $A \cap B^c = B^c \cap (A \cup B)$




Figura 1.10:

**Outras operações :**

- I.  $A \cap \emptyset = \emptyset$
- II.  $A \cup \emptyset = A$
- III.  $\emptyset^c = \Omega$
- IV.  $\Omega^c = \emptyset$
- V.  $(A^c)^c = A$
- VI.  $B = (A \cap B) \cup (A^c \cap B)$
- VII.  $A = (A \cap B) \cup (A \cap B^c)$

**Exemplo :** Escrever  $A \cup B$  como união de eventos disjuntos.




Figura 1.11:

**Situação 1:**  $(A \cup B) = A \cup (A^c \cap B)$

**Situação 2:**  $A \cup B = B \cup (A \cap B^c)$

Considerando a Situação 1 , vamos verificar se os eventos são disjuntos. Os eventos serão disjuntos se  $A \cap (A^c \cap B) = \emptyset$  . Vericando, temos:

$$\begin{aligned} (A \cap A^c) \cap B &= \emptyset \\ \emptyset \cap B &= \emptyset \end{aligned}$$

## 1.1 Definições de Probabilidade

### 1.1.1 Probabilidade em Espaços Equiprováveis

Se um experimento aleatório tiver  $n$  resultados possíveis,  $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$ , mutuamente exclusivos e igualmente possíveis e se um evento  $A$  tiver  $n_A$  desses resultados, então a probabilidade do evento  $A$ , representado por  $P(A)$ , é dada por:

$$P(A) = \frac{N_a}{n}, \quad A \subset \Omega \quad (1.1)$$

Sendo que  $\Omega$  é definido como todo o espaço amostral,  $n_A$  o número de casos favoráveis  $A$  e  $n$  o número de casos possíveis.

**Exemplo:** Dado o lançamento de duas moedas honestas, calcule a probabilidade de:

- (a) Obter duas faces iguais.
- (b) Obter pelo menos uma face diferente de cara
- (c) Obter pelo menos uma face diferente.

	c	k
c	(c,c)	(c,k)
k	(k,c)	(k,k)

$$\Omega = \{(c, c); (c, k); (k, c); (k, k)\}$$

- (a)  $A = \text{Faces iguais}$

$$A = \{(c, c); (k, k)\}$$

$$P(A) = \frac{2}{4} = \frac{1}{2} = 0.5$$

- (b)  $B = \text{Pelo menos uma face diferente de cara.}$

$$B = \{(c, k); (k, c); (k, k)\}$$

$$P(B) = \frac{3}{4}$$

- (c)  $C = \text{Obter pelo menos uma face diferente}$

$$C = \{(c, k); (k, c)\}$$

$$P(C) = \frac{2}{4} = \frac{1}{2}$$

### 1.1.2 Probabilidade Frequentista

Um experimento é realizado  $n$  vezes, sendo  $n$  um número grande. O evento  $A$  ocorre exatamente  $N_a$  vezes com:  $0 \leq N_a \leq n$ . A frequência relativa de vezes que ocorreu o evento  $A$  é uma forma de aproximar a probabilidade do evento  $A$ , ou seja:

$$f_r(A) = \frac{n_a}{n} \quad (1.2)$$

Quando  $n \rightarrow \infty$ ,  $f_r(A)$  aproxima-se de  $P(A)$ .

**Exemplo :**

Geração de  $n$  número inteiros entre 1 e 5,  $\{1, 2, 3, 4, 5\}$ , e o evento de interesse é a ocorrência do número 4.

### 1.1.3 Probabilidade axiomática

A probabilidade de um evento  $A$  é definida como sendo um número  $P(A)$  que satisfaz os seguintes axiomas:

- I.  $P(A) > 0, \forall A \subset \Omega$
- II.  $P(\Omega) = 1$
- III. Se  $A_1, A_2, \dots$  são eventos mutuamente exclusivos ( $A_i \cap A_j = \emptyset, \forall i \neq j$ ), então:

$$P(\cup_{i=1}^{\infty} A_i) = P(A_1 \cup A_2 \cup \dots) = \sum_{i=1}^{\infty} P(A_i) \quad (1.3)$$

**Propriedades :**

- (a)  $0 \leq P(A) \leq 1$
- (b)  $P(\emptyset) = 0$
- (c) Se  $A \subset \Omega$  então  $P(A) = 1 - P(A^c)$
- (d) Se  $A \subset B \subset \Omega$ , então  $P(A) \leq P(B)$
- (e) Se  $A, B \subset \Omega$ , então vale:

$$P(B) = P(B \cap A) + P(B \cup \bar{A}) \quad (1.4)$$

- (f) Se  $A, B \subset \omega$ , então:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (1.5)$$



(g) Se  $A, B, C \subset \omega$ , então:

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) \\ &\quad - P(B \cap C) + P(A \cap B \cap C) \end{aligned} \quad (1.6)$$

**Exemplo:** Mostre a propriedade (g).

Use o fato de que  $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$ :

$$\begin{aligned} &P(A \cup B \cup C) \\ &= P(A \cup (B \cup C)) \\ &= P(A) + P(B \cup C) - P(A \cap (B \cup C)) \\ &= P(A) + P(B) + P(C) - P(B \cap C) - P((A \cap B) \cup (A \cap C)) \\ &= P(A) + P(B) + P(C) - P(B \cap C) \\ &\quad - (P(A \cap B) + P(A \cap C) - P((A \cap B) \cap (A \cap C))) \\ &= P(A) + P(B) + P(C) - P(B \cap C) - P(A \cap B) - P(A \cap C) + P(A \cap B \cap C) \end{aligned}$$

**Exercício:** Considere um experimento aleatório e os eventos  $A$  e  $B$  associados, tais que:

$$\begin{aligned} P(A) &= \frac{1}{2} \\ P(B) &= \frac{1}{3} \\ P(A \cap B) &= \frac{1}{4} \end{aligned}$$

Calcule as probabilidades:

(a)  $P(\bar{A} \cap \bar{B})$

(b)  $P(\bar{A} \cup \bar{B})$

(a)

$$\begin{aligned} P(A^c \cap B^c) &= 1 - P(A \cup B) \\ &= 1 - \{P(A) + P(B) - P(A \cap B)\} \\ &= 1 - \left\{\frac{1}{2} + \frac{1}{3} - \frac{1}{4}\right\} = \frac{5}{12} \end{aligned}$$

(b)

$$\begin{aligned} P(A^c \cup B^c) &= P((A \cap B)^c) \\ &= 1 - P(A \cap B) = 1 - \frac{1}{4} = \frac{3}{4} \end{aligned}$$

Ou de maneira similar:

$$\begin{aligned} P(A^c \cup B^c) &= P(A^c) + P(B^c) - P(A^c \cap B^c) \\ &= (1 - P(A)) + (1 - P(B)) - \frac{5}{12} \\ &= (1 - \frac{1}{2}) + (1 - \frac{1}{3}) - \frac{5}{12} \end{aligned}$$

### 1.1.4 Probabilidade Condicional

Sejam  $A$  e  $B$  dois eventos definidos em um mesmo espaço amostral  $\Omega$ . A probabilidade de  $A$  dado que ocorre o evento  $B$ , denotada por  $P(A/B)$  é definida por:

$$P(A/B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0. \quad (1.7)$$

Consequentemente, podemos escrever:

Figura 1.12: Name

$$P(A \cap B) = P(A/B) \cdot P(B) \quad (1.8)$$

Conhecida como regra do produto.

**Observação:**

$$P(B/A) = \frac{P(B \cap A)}{P(A)} = \frac{P(A \cap B)}{P(A)} \quad (1.9)$$

$$P(A \cap B) = P(B/A) \times P(A) \quad (1.10)$$

Logo:

$$P(A \cap B) = P(B/A) \times P(A) \quad (1.11)$$

$$= P(A/B) \times P(B) \quad (1.12)$$

**Exemplo :** Suponha que um escritório possua 100 computadores de tipos Desktop (D) e Laptop (L) sendo alguns novos (N) e outro com um certo tempo de uso (U), distribuídos da seguinte forma:

	D	L	Total
N	40	30	70
U	20	10	30
Total	60	40	100

Um funcionário escolhe um laptop ao acaso. Qual a probabilidade de que seja novo?

**Resolução:**

$$P(N/L) = \frac{P(N \cap L)}{P(L)} = \frac{\frac{30}{100}}{\frac{40}{100}} = \frac{3}{4}$$

Obs:  $P(A \cap B)$  e  $P(A/B)$

## 1.2 Árvore de Probabilidades

Sejam  $A, B \subset \Omega$ . Uma representação bastante útil é a árvore de probabilidades.




Figura 1.13: Um exemplo de uma árvore de probabilidades

**Exemplo :** No exemplo anterior, qual a probabilidade de um funcionário selecionar um desktop usado?




Figura 1.14: Arvore de probabilidade Desktop/Laptop/Usado/Novo

$$P(D \cap U) = P(D/U)P(U)$$

Ou:

$$P(D \cap U) = P(U/D)P(D) = \frac{20}{60} \times \frac{60}{100} = 0,2$$

**Algumas propriedades :**

- (a)  $P(\emptyset/B) = 0$
- (b) Se  $A \subset \Omega$ , então  $P(A^c/B) = 1 - P(A/B)$
- (c) Se  $A, C \subset \Omega$ , então:

$$P(A \cup C/B) = P(A/B) + P(C/B) - P(A \cap C/B) \quad (1.13)$$

### 1.3 Independência de Eventos

**Definição :** Dois eventos  $A$  e  $B$  definidos em  $\Omega$  são independentes se a informação da ocorrência ou não de  $B$  não altera a probabilidade de ocorrência de  $A$ . Isto é:

$$P(A/B) = P(A), \quad P(B) > 0. \quad (1.14)$$

Logo, dois eventos  $A$  e  $B$  são independentes se, e somente se,  $P(A \cap B) = P(A) \times P(B)$ .

**Observação :**

$$P(A/B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)P(B)}{P(B)} = P(A)$$

**Exemplo :** Um estudante se inscreve em dois processos seletivos com probabilidade 30% de ser aprovado na empresa *I* e 50% de ser aprovado na empresa *II*. Se as aprovações são independentes, qual a probabilidade de que ele seja aprovado em pelo menos uma?

Definindo os eventos:

A: O estudante ser aprovado na empresa *I*.

B: O estudante ser aprovado na empresa *II*.

$$P(A) = 0.30$$

$$P(B) = 0.50$$

$$\begin{aligned} P(A \cup B) &= P(A) + P(B) - P(A \cap B) \\ &= P(A) + P(B) - P(A) \times P(B) \\ &= 0.3 + 0.5 - 0,3 \times 0,5 \\ &= 0.65 \end{aligned}$$


### 1.3.1 Independência de três eventos

**Definição:** Os eventos A,B,C em  $\Omega$  são independentes se e somente se:

- (a)  $P(A \cap B) = P(A) \times P(B)$
- (b)  $P(A \cap C) = P(A) \times P(C)$
- (c)  $P(B \cap C) = P(B) \times P(C)$
- (d)  $P(A \cap B \cap C) = P(A) \times P(B) \times P(C)$

**Resultado :** Se A,B são eventos independentes em  $\Omega$ , então:

1.  $A$  e  $B^c$  são independentes.
2.  $A^c$  e  $B$  são independentes.
3.  $A^c$  e  $B^c$  são independentes.



**Prova:** Resultado 1

$$\begin{aligned} P(A \cap B^c) &= P(A) - P(A \cap B) \\ &= P(A) - P(A) \times P(B) \\ &= P(A)(1 - P(B)) \\ &= P(A) \times P(B^c) \end{aligned}$$

**Observação :** Não confundir eventos mutuamente exclusivos com eventos independentes. Ou seja, não confunda  $P(A \cap B) = 0$  com  $P(A \cap B) = P(A) \times P(B)$ .

**Exemplo :** Um atirador acerta 80% dos disparos e outro acerta, nas mesmas condições acerta 70%. Qual a probabilidade de o alvo ser acertado se ambos os atiradores disparam simultaneamente?

A: Atirador 1 acerta o alvo

B: Atirador 2 acerta o alvo

**Resolução :** A intersecção de dois eventos independentes é dada pela multiplicação de suas probabilidades:

$$\begin{aligned} P(A \cap B) &= P(A)P(B) \\ &= 0.8 \times 0.7 = 0.56 \end{aligned}$$

Logo a probabilidade de interesse é dada pela a união de dois eventos:


$$\begin{aligned} P(A \cup B) &= P(A) + P(B) - P(A \cap B) \\ &= P(A) + P(B) - P(A) \times P(B) \\ &= 0.8 + 0.7 - 0.8 \times 0.7 \\ &= 0.94 \end{aligned}$$

## 1.4 O Teorema de Bayes

### 1.4.1 Partições do espaço amostral

**Definição :** Uma coleção de eventos  $A_1, A_2, \dots, A_k$  formam uma partição do espaço amostral  $\Omega$  se:

- I.  $A_i \cap A_j = \emptyset, \forall i \neq j$ , com  $i, j = 1, \dots, k$
- II.  $\cup_{i=1}^k A_i = \Omega$

Figura 1.15: Espaço amostral com  $k$  particoes

### 1.4.2 Lema da probabilidade total

**Definição:** Se  $A_1, \dots, A_k$  é uma partição de  $\Omega$ , então para qualquer evento  $B$  de  $\Omega$ , vale:

$$\begin{aligned} P(B) &= P\left(\sum_{i=1}^k B(B \cap A_i)\right) \\ &= \sum_{i=1}^k P(B/A_i)P(A_i). \end{aligned} \quad (1.15)$$

Vejamos:

$$B = \cup_{i=1}^k (A_i \cap B) \quad (1.16)$$

$$\begin{aligned} P(B) &= P\left(\cup_{i=1}^k (A_i \cap B)\right) \\ &= \sum_{i=1}^k P(B/A_i)P(A_i) \end{aligned} \quad (1.17)$$

### 1.4.3 Fórmula de Bayes

**Definição** Se  $A_1, A_2, \dots, A_k$  formam uma partição de  $\Omega$  e  $B \subset \Omega$  com  $P(B) > 0$ , então:

$$\begin{aligned} P(A_i/B) &= \frac{P(A_i \cap B)}{P(B)} \\ &= \frac{P(B/A_i)P(A_i)}{\sum_{j=1}^k P(B/A_j)P(A_j)} \end{aligned} \quad (1.18)$$

**Exemplo 1 :**

Uma montadora trabalha com dois fornecedores A e B de uma determinada peça. Sabe-se que 10% e 5% das peças provenientes dos fornecedores A e B respectivamente, estão fora de especificação. A montadora recebe 30% das peças do fornecedor A e 70% do fornecedor B. Se uma peça do estoque inteiro é escolhido ao acaso, calcule:

- (a) A probabilidade que ela esteja fora de especificação.
- (b) Se uma peça é escolhida ao acaso está fora de especificação, qual é a probabilidade de que tenha sido fornecido por A?

A: Peça é do fornecedor A.

B: Peça é do fornecedor B.

C: Peça está fora de especificação.

$$P(A) = 0.3$$

$$P(B) = 0.7$$

$$P(C/A) = 0.10$$

$$P(C/B) = 0.05$$

- (a)  $P(C) = ?$

Usando o lema da probabilidade total:

$$\begin{aligned} P(C) &= P(A \cap C) \cup P(B \cap C) \\ P(C) &= P(A \cap C) + P(B \cap C) \\ &= P(C/A)P(A) + P(C/B)P(B) \\ &= 0,1 \times 0,3 + 0,05 \times 0,7 \\ &= 0.065 \end{aligned}$$



(b)  $P(A/C) = ?$

$$\begin{aligned} P(A/C) &= \frac{P(A \cap C)}{P(C)} \\ &= \frac{P(C/A)P(A)}{P(C/A)P(A) + P(C/B)P(B)} \\ &= \frac{0.1 \times 0.3}{0.065} = 0.4615 \end{aligned}$$

**Exemplo 2:** Estudos revelaram que 40% dos estudantes universitários já experimentaram algum tipo de droga ilícita. Uma universidade resolve aplicar um teste com detector de mentira para descobrir se seus estudantes já usaram algum tipo de droga ilícita. Sabemos que se o estudante já usou algum tipo de droga o detector vai dar positivo com certeza. Porém, sabemos que o detector erra, ou seja, apresenta um falso positivo em 5% quando aplicado em estudantes que nunca usaram drogas.

Se um estudante é selecionado aleatoriamente e o teste aplicado nele deu positivo, qual a probabilidade de ele já ter usado algum tipo de droga?

A: O estudante já usou droga.

B: O detector deu positivo.

$$\begin{aligned} P(A) &= 0.4 \\ P(B/A) &= 1 \\ P(B/A^c) &= 0.05 \\ P(A/B) &= ? \end{aligned}$$

$$\begin{aligned} P(A/B) &= \frac{P(A \cap B)}{P(B)} \\ &= \frac{P(B/A)P(A)}{P(B/A) \times P(A) + P(B/A^c) \times P(A^c)} \\ &= \frac{1 \times 0.4}{1 \times 0.4 + 0.05 \times 0.6} \\ &= 0.93 \end{aligned}$$

**Exercício :** Para selecionar seus funcionários uma empresa oferece aos candidatos um curso de treinamento durante uma semana. No final do curso, eles são classificados em uma prova; 25% são classificados como bons ( $B$ ), 50% como médios ( $M$ ) e os 25% restantes como fracos ( $F$ ).

A empresa pretende substituir o treinamento por um teste contendo questões de conhecimentos gerais. Para isso gostaria de conhecer qual a probabilidade de um indivíduo aprovado no teste ser considerado fraco ( $F$ ), se fizesse o curso. Assim, antes do início do curso, os candidatos do curso, foram submetidos ao teste e receberam o conceito aprovado ( $A$ ) ou reprovado ( $R$ ). No final do curso, obtiveram-se as seguintes probabilidades condicionais:

$$P(A/B) = 0,8$$

$$P(A/M) = 0,5$$

$$P(A/F) = 0,2$$

**Resposta :** 0.1

## 1.5 Variáveis Aleatórias

**Definição :** Seja um experimento aleatório e  $\Omega$  o espaço amostral associado a esse experimento. Uma função  $X(\omega)$  que associa cada elemento  $\omega \in \Omega$  a um número real  $x = x(\omega)$  é denominada variável aleatória (v.a.).




Figura 1.16: Representação da variável aleatória que associa  $\omega_i$  a um  $x_i$

**Notação :**  $X : \Omega \rightarrow \mathbb{R}$

**Exemplo :** Lançamento de uma moeda duas vezes. A v.a. ,  $x$ , é o  $n^o$  de caras.

	c	k
c	(c,c)	(c,k)
k	(k,c)	(k,k)

$$\begin{aligned}
\Omega : & \left\{ \underbrace{cc}_{\omega_1}; \underbrace{kc}_{\omega_2}; \underbrace{kc}_{\omega_3}; \underbrace{kk}_{\omega_4} \right\} \\
X : & \quad n^\circ \text{ de caras} \\
X(\omega_1) = X((c, c)) = x(\omega_1) = & 2 \\
X(\omega_2) = X((k, c)) = x(\omega_2) = & 1 \\
X(\omega_3) = X((c, k)) = x(\omega_3) = & 1 \\
X(\omega_4) = X((k, k)) = x(\omega_4) = & 0 \\
R_x : & \{0, 1, 2\} \\
P(x = 0) = & ? \\
P(x = 1) = & ? \\
P(x = 2) = & ? \\
X = & \begin{cases} 0, & \text{se ocorrer } (k, k) \\ 1, & \text{se ocorrer } (c, k) \text{ ou } (k, c) \\ 2, & \text{se ocorrer } (c, c) \end{cases}
\end{aligned}$$

**Exemplo :** Em uma linha de produção, peças são classificadas em defeituosas ou não defeituosas. Podemos definir a v.a.  $X$  como:

$$\begin{cases} x = 1, & \text{se a peça é defeituosa} \\ 0, & \text{a peça não é defeituosa} \end{cases}$$

**Observação :** Uma v.a.  $X$  desse tipo é chamada de v.a. de Bernoulli. Nesse caso,  $\Omega = \{\text{peça defeituosa}, \text{peça não defeituosa}\}$

### 1.5.1 Classificação de Variáveis Aleatórias

**Definição :** Se a v.a.  $X$  assume valores em um conjunto finito ou infinito e numerável é chamado de variável aleatória discreta. Se  $X$  assume valores, em um conjunto infinito não-enumerável, é chamada de v.a. contínua.

**Exemplos :**

- (a)  $x$  indica o  $n^\circ$  de residentes em um domicílio.  $X$  pode assumir valores em  $\mathbb{N}$  e assim é chamada de v.a. discreta.
- (b)  $Y$  indica o tempo de vida (em horas) de um equipamento eletrônico.  $Y$  pode assumir valores em  $\mathbb{R}^+$  e assim é chamado de v.a. contínua.

### 1.5.2 Função Massa de Probabilidade

**Definição :** Seja  $X$  uma v.a. discreta que assume valores em  $R_x = \{x_1, x_2, \dots, x_k, \dots\}$ .

A cada possível  $x_i$ , associamos um número,

$$P_i = p(x_i) = P(X = x_i) = P(X(\omega_i) = x_i),$$

$$\omega_i \in \Omega, x_i \in R_x$$

dito probabilidade de  $x_i$ . A função  $p(x)$  é definida como função massa de probabilidade (f.m.p) de  $X$ .

As probabilidades  $p(x_i)$  devem satisfazer as seguintes condições:

- (i)  $p(x_i) > 0, \forall x_i \in R_x$
- (ii)  $\sum_{i=1}^{\infty} p(x_i) = 1$

**Interpretação da f.m.p :**

Seja  $x$  uma v.a. discreta com  $R_x = \{x_1, x_2, \dots, x_k\}$  e  $p(x_i) = p_i$ .




Figura 1.17: Exemplo de uma função massa probabilidade

**Exemplo:** Lançamento de uma moeda duas vezes e  $x$  é o número de caras.

$$\Omega = \left\{ \underbrace{cc}_2; \underbrace{ck}_1; \underbrace{kc}_1; \underbrace{kk}_0 \right\}$$

$$R_x = \{0, 1, 2\}$$

A f.m.p de  $x$  é dada por:

x	0	1	2
$P(x) = P(X = x)$	1/4	1/2	1/4

$$\begin{aligned}
 p(0) &= P(X = 0) = P((k, k)) = \frac{1}{4} \\
 p(1) &= P(X = 1) = P((c, k)) + P((k, c)) = \frac{2}{4} = \frac{1}{2} \\
 p(2) &= P(X = 2) = P((c, c)) = \frac{1}{4} \\
 P(X = x) &= \begin{cases} 1/4, & \text{se sair } kk \text{ ou } cc \text{ ou } x = 0 \text{ ou } x = 2 \\ 1/2, & \text{se sair } ck \text{ ou } kc \text{ ou } x = 1 \end{cases}
 \end{aligned}$$

**Exemplo:** Um carregamento de 8 computadores contém 3 defeituosos. Se uma empresa de uma compra aleatória de dois computadores, apresente a f.m.p para o número de computadores com defeitos adquiridos.

$X$  : número de computadores defeituosos

$$R_x = \{0, 1, 2\}$$

$$P(X = 0) = \frac{\binom{3}{0}\binom{5}{2}}{\binom{8}{2}} = 5/14$$

**Obs:**

$$\binom{8}{2} = \frac{8!}{2!(8-2)!}$$

$$P(X = 1) = \frac{\binom{3}{1}\binom{5}{1}}{\binom{8}{2}} = 15/28$$

$$P(X = 2) = \frac{\binom{3}{2}\binom{5}{0}}{\binom{8}{2}} = 3/28$$

Então a f.m.p. é:

x	0	1	2	Total
$P(x)$	$\frac{10}{28}$	$\frac{15}{28}$	$\frac{3}{28}$	1

**Exemplo:** A demanda diária de um item é uma v.a. discreta com f.m.p. dada por:

$$P(D = d) = \frac{2^d k}{d!}, \quad d = 1, 2, 3, 4 \quad (1.19)$$

(a) Determine a constante  $k$

(b) Calcule  $P(D > 2)$

(a) Sabemos que:

$$\begin{aligned} \sum_{i=1}^n p(x_i) &= 1, \forall x_i \in R_x \\ P(D=1) + P(D=2) + P(D=3) + P(D=4) &= 1 \\ \frac{2^1 k}{1!} + \frac{2^2 k}{2!} + \frac{2^3 k}{3!} + \frac{2^4 k}{4!} &= 1 \\ 2K + 2K + \frac{4K}{3} + \frac{2K}{3} &= 1 \\ 4K + \frac{6K}{3} &= 1 \\ 6K &= 1 \\ K &= \frac{1}{6} \end{aligned}$$

Então o f.m.p de  $x$  é:

$$P(D=d) = \frac{2^d}{6d!}, \quad d = 1, 2, 3, 4$$

(b)

$$\begin{aligned} P(D > 2) &= P(D \geq 3) \\ &= P(D=3) + P(D=4) \\ &= \frac{2^3}{6 \times 3!} + \frac{2^4}{6 \times 4!} \\ &= \frac{1}{3} \end{aligned}$$

ou

$$\begin{aligned} P(D > 2) &= 1 - P(D \leq 2) \\ &= 1 - \{P(D=1) + P(D=2)\} \\ &= 1 - P(D=1) - P(D=2) \end{aligned}$$

Obs:  $R_x : \{0, 1, 2, 3, 4, 5\}$

$$P(X > 1) = P(x=2) + P(x=3) + \dots + P(x=5)$$

ou

$$\begin{aligned} P(x > 1) &= 1 - P(x \leq 1) \\ &= 1 - \{P(x=0) + P(x=1)\} \\ &= P(x > 1) + P(x \leq 1) = 1 \end{aligned}$$

### 1.5.3 Densidade de Probabilidade

**Definição:** Seja  $X$  uma v.a. contínua que assume valores em  $R_x, R_x \in \mathbb{R}$ .

A função  $f(x)$  é a função densidade de probabilidade (f.d.p) para  $x$ , se satisfaz as seguintes propriedades:

- (i)  $f(x) \geq 0, \forall x \in R_x$
- (ii)  $\int_{R_x} f(x)dx = \int_{-\infty}^{\infty} f(x)dx = 1$
- (iii)  $P(a < x < b) = \int_a^b f(x)dx$

Uma ilustração de f.d.p:




Figura 1.18:

**Obs:** Se  $X$  é uma v.a. contínua assumindo valores em  $R_x$ , então para toda  $a \in R_x$ , temos:

- (a)  $P(x = a) = 0$
- (b)  $P(x > a) = P(x \geq a)$
- (c)  $P(x < a) = P(x \leq a)$
- (d)  $P(x > a) = 1 - P(x \leq a)$   
 $= 1 - P(x < a)$
- (e)  $P(x < a) = 1 - P(x \geq a)$   
 $= 1 - P(x > a)$

Outros exemplos:

$$\begin{aligned} P(a \leq x \leq b) &= P(a \leq x < b) \\ &= P(a < x \leq b) = P(a < x < b) \end{aligned}$$

Obs: Só vale para v.a. contínua.

**Exemplo:** O tempo de produção de um componente (em minutos) é uma v.a. com função densidade de probabilidade dada por:

$$f(x) = \begin{cases} \frac{5-x}{4}, & \text{se } 2 < x < 4 \\ 0, & \text{caso contrário} \end{cases} \quad (1.20)$$

- (a) Mostre que  $f(x)$  é uma f.d.p
- (b) Calcule a probabilidade de que o tempo de produção de um componente seja menor do que 3 minutos.

(a) Devemos verificar:

- i.  $f(x) \geq 0, \forall x \in R_x$
- ii.  $\int_{R_x} f(x)dx = 1$

Verificando:

- i.  $f(x) \geq 0, \forall x \in 2 < x < 4$
- ii.

$$\begin{aligned} \int_2^4 \frac{5-x}{4} dx &= 1 \\ \int_2^4 5dx - \int_2^4 xdx &= \frac{1}{4} \left( 5x \Big|_2^4 - \frac{x^2}{2} \Big|_2^4 \right) \\ &= \frac{1}{4} \left( 5(4-2) - \frac{1}{2}(16-4) \right) = 1 \end{aligned}$$

Portanto,  $f(x)$  é uma função densidade de probabilidade

(b)

$$\begin{aligned} P(X < 3) &= \int_{-\infty}^{(3)} f(x)dx \\ &= \int_{-\infty}^2 0dx + \int_2^3 \frac{5-x}{4} dx \end{aligned}$$



$$\begin{aligned}
P(X < 3) &= \int_2^3 \frac{5-x}{4} dx \\
&= \frac{1}{4} \left( \int_2^3 5 dx - \int_2^3 x dx \right) \\
&= \frac{1}{4} \left( 5 \times 1 - \frac{1}{2} \times 5 \right) = \frac{5}{8} \\
P(A/B) &= \frac{P(A \cap B)}{P(B)}
\end{aligned}$$

**Exemplo:** Seja  $x$  uma v.a. contínua com f.d.p dada por:

$$f(x) = \begin{cases} 2x, & 0 \leq x \leq 1 \\ 0, & \text{Caso contrário} \end{cases}$$

(a) Verifique se  $f(x)$  é uma f.d.p

(b)  $P(x \leq \frac{1}{2})$

(c)  $P(X \leq \frac{1}{2} / \frac{1}{3} \leq x \leq \frac{2}{3})$

(a) Devemos verificar:

i.  $f(x) \geq 0, \forall x \in R_x$

ii.  $\int_{R_x} f(x) dx = 1$

Verificando:

i.

$$f(x) \geq 0, \forall x \in 0 < x < 1$$

ii.


$$\begin{aligned}
\int_{R_x} 2x dx &= \int_0^1 2x dx \\
&= \frac{2x^2}{2} \Big|_0^1 = 1
\end{aligned}$$

Portanto,  $f_x(x)$  é uma f.d.p.

(b)

$$\begin{aligned}
 P(X \leq 1/2) &= \int_{-\infty}^{1/2} f_x(x) dx \\
 &= \int_{-\infty}^0 0 dx + \int_0^{1/2} 2x dx \\
 &= x^2 \Big|_0^{1/2} \\
 &= \frac{1}{4}
 \end{aligned}$$

(c) Probabilidade Condicional



$$\begin{aligned}
 P(A/B) &= \frac{P(A \cap B)}{P(B)} \\
 &= \frac{P(X \leq \frac{1}{2}) \cap P(\frac{1}{3} \leq X \leq \frac{2}{3})}{P(\frac{1}{3} \leq X \leq \frac{2}{3})} \\
 &= \frac{P(\frac{1}{3} \leq X \leq \frac{1}{2})}{P(\frac{1}{3} \leq X \leq \frac{2}{3})} \\
 &= \frac{\int_{\frac{1}{3}}^{\frac{1}{2}} 2x dx}{\int_{\frac{1}{3}}^{\frac{2}{3}} 2x dx} \\
 &= \frac{x^2 \Big|_{\frac{1}{3}}^{\frac{1}{2}}}{x^2 \Big|_{\frac{1}{3}}^{\frac{2}{3}}} \\
 &= \frac{5}{12}
 \end{aligned}$$

### 1.5.4 Função distribuição acumulada discreta

**Definição:** Seja  $x$  uma v.a. discreta que assume valores em  $R_x$  e com f.m.p.  $p(x) = P(X = x)$ . Para qualquer  $x \in \mathbb{R}$ , a função de distribuição acumulada(f.d.a) de  $x$ , denotada por  $F_x(x)$ , é definida como:

$$F_x(x) = P(X \leq x) = \sum_{x_i \in R_x} P(X = x_i) = \sum_{x_i \in R_x} p(x_i), \quad \forall x_i \leq x$$

De forma mais clara, temos como exemplo:

$$\begin{aligned} R_x &= \{0, 1, 2, 3, 4\} \\ F_x(2, 3) &= P(X \leq 2, 3) \\ &= P(x = 0) + P(x = 1) + P(x = 2) \end{aligned}$$

**Exemplo:** Considere o lançamento de uma moeda duas vezes e  $x$  é o número de caras. Já sabemos que a f.m.p de  $x$  é dada por:

x	0	1	2
$P(X = x)$	$\frac{1}{5}$	$\frac{1}{2}$	$\frac{1}{4}$

Com  $R_x = \{0, 1, 2\}$

Ou, de forma equivalente podemos escrever:

$$p(x) = P(X = x) = \begin{cases} \frac{1}{4}, & \text{se } x = 0, 2 \\ \frac{1}{2}, & \text{se } x = 1 \\ 0, & \text{caso contrário} \end{cases}$$

A f.d.a de  $x$  é dada por:

$$F_x = P(X \leq x) = \begin{cases} 0, & x < 0 \\ \frac{1}{4}, & 0 \leq x < 1 \\ \frac{3}{4}, & 1 \leq x < 2 \\ 1, & x \geq 2 \end{cases}$$

A representação gráfica de  $F_x(x)$  é:




Figura 1.19:

### 1.5.5 Função distribuição acumulada contínua

**Definição:** Seja  $x$  uma v.a. contínua que assume valores em  $R_x$  e com f.d.p  $f(x)$ . Para qualquer  $x \in \mathbb{R}$ , a f.d.p de  $x$ , denotada por  $F_x(x)$  é definida como:

$$F_x(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt \quad (1.21)$$

**Observação:**  $F_x(x) = P(X \leq a) = \int_{-\infty}^a f(t)dt, \quad a \in \mathbb{R}$

Como consequência imediata podemos escrever dois resultados:

$$P(a < x < b) = \int_a^b f(x)dx \quad (1.22)$$

$$= F_x(b) - F_x(a) \quad (1.23)$$

$$f(x) = \frac{\partial F_x(x)}{\partial x}, \quad \text{se a derivada existir} \quad (1.24)$$

**Exemplo:** Considere a f.d.p dada por:

$$f(x) = \begin{cases} \frac{x^2}{3}, & -1 < x < 2 \\ 0, & \text{caso contrário} \end{cases}$$

Determine  $F_x(x)$  e use-a para avaliar  $P(0 \leq x < 1)$ .

A f.d.a de  $x$  é dada por:

$$\begin{aligned} F_x(x) &= P(X \leq x) = \int_{-\infty}^x f_x(t) dt \\ &= \int_{-\infty}^x \frac{t^2}{3} dt, \quad -1 < t < 2 \\ &\quad \int_{-1}^x \frac{t^2}{3} dt = \frac{1}{9} t^3 \Big|_{-1}^x \\ F_x(x) &= \frac{1}{9} (x^3 + 1) \end{aligned}$$

$$F_x(x) = P(X \leq x) = \begin{cases} 0, & x < -1 \\ \frac{1}{9}(x^3 + 1), & -1 \leq x < 2 \\ 1, & x \geq 2 \end{cases}$$

$$P(0 \leq x < 1) = ?$$

$$P(0 \leq x < 1) = F_x(1) - F_x(0)$$

$$P(x \leq 1) - P(x \leq 0) = \frac{1}{9}(1^3 + 1) - \frac{1}{9}(0^3 + 1)$$

$$P(0 \leq x < 1) = \frac{2}{9} - \frac{1}{9} = \frac{1}{9}$$

Ou

$$P(0 \leq X < 1) = \int_0^1 \frac{x^2}{3} dx$$

### 1.5.6 Propriedades de f.d.a

- (a)  $F_x(x)$  é uma função contínua.
- (b)  $F_x(x)$  é uma função monótona não decrescente.
- (c)  $0 \leq F_x(x) \leq 1, \quad \forall x \in \mathbb{R}$
- (d)  $\lim_{x \rightarrow -\infty} F_x(x) = 0$  e  $\lim_{x \rightarrow +\infty} F_x(x) = 1$
- (e)  $P(x \leq a) = F_x(a)$

$$(f) \quad P(x > a) = 1 - P(x \leq a) = 1 - F_x(a)$$

$$(g) \quad P(a < x \leq b) = F_x(b) - F_x(a)$$

**Exemplo:** Seja  $x$  uma v.a. contínua com f.d.p dada por:

$$f_x(x) = \begin{cases} kx^2, & 0 < x < 1 \\ 0, & \text{c.c.} \end{cases}$$

(a) Achar  $k$ .

(b) Determine  $F_x(x)$ .

(c)  $P(\frac{1}{3} < x < \frac{1}{2})$

(a)

$$\int_{R_x} f(x) dx = 1$$

$$k \int_0^1 x^2 dx = 1$$

$$\frac{k}{3} x^3 \Big|_0^1 = 1$$

$$\frac{k}{3} = 1 \therefore k = 3$$

Logo, a f.d.p de  $X$  é:

$$f_x(x) = \begin{cases} 3x^2, & 0 < x < 1 \\ 0, & \text{c.c.} \end{cases}$$

(b)  $F_x(x) = ?$

$$\begin{aligned} F_x &= P(X \leq x) = \int_{-\infty}^x f_x(t) dt \\ &= \int_0^x 3t^2 dt = t^3 \Big|_0^x = x^3 \end{aligned}$$

Assim, a f.d.a. é dada por:

$$F_x(x) = \begin{cases} 0, & x < 0 \\ x^3, & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

(c)

$$\begin{aligned}
 P\left(\frac{1}{3} < X < \frac{1}{2}\right) &= F_x\left(\frac{1}{2}\right) - F_x\left(\frac{1}{3}\right) \\
 &= \left(\frac{1}{2}\right)^3 - \left(\frac{1}{3}\right)^3 \\
 &= \frac{1}{8} - \frac{1}{27} \\
 &= \frac{19}{216}
 \end{aligned}$$

Ou

$$P\left(\frac{1}{3} < x < \frac{1}{2}\right) = \int_{\frac{1}{3}}^{\frac{1}{2}} 3x^2 dx = \frac{19}{216}$$

**Exemplo:**Seja  $F_x$  dada por:

$$F_x = \begin{cases} 0, & \text{se } x < 0 \\ \frac{1}{8}, & \text{se } 0 \leq x < 1 \\ \frac{1}{2}, & \text{se } 1 \leq x < 2 \\ \frac{5}{8}, & \text{se } 2 \leq x < 3 \\ 1, & \text{se } x \geq 3 \end{cases}$$

Determine:

- (a)  $P(1 < x \leq 3)$
- (b)  $P(x > 2)$
- (c) Encontre a  $P(x)$

(a)

$$P(1 \leq X \leq 3) = F_x(3) - F_x(1) = \frac{1}{2}$$

(b)

$$\begin{aligned}
 P(X > 2) &= 1 - F_x(2) \\
 &= 1 - \frac{5}{8} = \frac{3}{8}
 \end{aligned}$$

(c)

$$F_x(0) = P(X \leq 0) = \frac{1}{8}$$

$$P(X = 0) = \frac{1}{8}$$

$$F_x(1) = P(X \leq 1) = \frac{1}{2}$$

$$P(X = 0) + P(X = 1) = \frac{1}{2}$$

$$P(X = 1) = \frac{1}{2} - \frac{1}{8} = \frac{3}{8}$$

$$F_x(2) = P(X \leq 2) = \frac{5}{8}$$

$$P(X = 0) + P(X = 1) + P(X = 2) = \frac{5}{8}$$

$$F_x(1) + P(X \leq 2) = \frac{5}{8}$$

$$P(X = 2) = \frac{5}{8} - \frac{1}{2} = \frac{1}{8}$$

$$F_x(3) = P(X \leq 3) = 1$$

$$\underbrace{P(X = 0) + P(X = 1) + P(X = 2)}_{F_x(2)} + P(X = 3) = 1$$

$$P(X = 3) = 1 - \frac{5}{8} = \frac{3}{8}$$

Assim temos:

x	0	1	2	3
$P(X = x)$	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{1}{8}$	$\frac{3}{8}$

## 1.6 Esperança Matemática de uma Variável Aleatória

**Definição:** Seja  $X$  uma v.a. com f.m.p.  $p_x(x)$  (no caso discreto) ou f.d.p  $f_x(x)$  (no caso contínuo). Chamamos de esperança matemática ou valor médio de  $X$  ao valor:

$$\mu_x = E(X) = \sum_{x \in R_x} x p_x(x), \quad \text{no caso discreto} \quad (1.25)$$

$$\mu_x = E(X) = \int_{x \in R_x} x f_x(x) dx, \quad \text{no caso contínuo} \quad (1.26)$$

Considerando  $a, b \in \mathbb{R}$ , constantes, temos algumas propriedades:



1.6. ESPERANÇA MATEMÁTICA DE UMA VARIÁVEL ALEATÓRIA 33

(a)

$$E(aX) = aE(x) \quad (1.27)$$

(b) Se  $X = a$ ,

$$E(X) = E(a) = a \quad (1.28)$$

(c)

$$E(E(X)) = E(X) \quad (1.29)$$

(d)

$$E(\pm a) = E(X) \pm a \quad (1.30)$$

(e)

$$E(ax + b) = aE(X) + b \quad (1.31)$$

(f)

$$E(ax + by) = aE(X) + bE(Y) \quad (1.32)$$

**Exemplo:** Considere a v.a.  $x$  com f.d.p dada por:

$$f_x(x) = \begin{cases} 2x, & 0 \leq x \leq 1 \\ 0, & \text{caso contrário} \end{cases}$$

Calcular o  $E(X)$ :

$$E(X) = \int_{R_x} x f_x(x) dx$$

$$\begin{aligned} E(X) &= \int_0^1 x \times 2x dx = 2 \int_0^1 x^2 dx \\ &= \frac{2}{3} x^3 \Big|_0^1 = \frac{2}{3} \end{aligned}$$

**Resultado:** Seja  $X$  uma v.a. com f.m.p  $p_x(x)$  ou f.d.p  $f_x(x)$ . Uma função de  $X$ , dita  $g(x)$ , é também uma v.a. e:

$$\begin{aligned} \mu = E(g(x)) &= \sum_{x \in R_x} g(x) p_x(x) = \sum_{x \in R_x} g(x) P(X = x), \quad \text{no caso discreto} \\ \mu = E(g(x)) &= \int_{R_x} g(x) f_x(x) dx, \quad \text{no caso contínuo} \end{aligned} \quad (1.33)$$

## 1.7 Variância

**Definição:** Seja  $x$  uma v.a. com f.m.p  $p_x(x)$  ou f.d.p  $f_x(x)$ , com média  $\mu_x = E(x)$ . Chamamos de variância da v.a.  $X$  o valor:

$$\sigma^2 = var(x) = E\left((X - E(X))^2\right) \quad (1.34)$$

$$= E\left((x - \mu)^2\right), \quad (1.35)$$

Ou seja,

$$\sigma^2 = var(x) = \sum_{x \in R_x} (x - \mu_x)^2 P(X = x) \quad \text{no caso discreto} \quad (1.36)$$

$$\sigma^2 = var(x) = \int_{R_x} (x - \mu_x)^2 f_x(x) dx \quad \text{no caso contínuo} \quad (1.37)$$

A raiz quadrada da variância ( $\sqrt{\sigma^2} = \sqrt{var(x)}$ ) é o desvio padrão, denotado por  $\sigma$ .

**Resultado:** Podemos escrever a variância v.a.  $x$  por:

$$\sigma^2 = var(x) = E(X^2) - (E(X))^2 \quad (1.38)$$

$$\sigma^2 = E(X^2) - (\mu_x)^2 \quad (1.39)$$

**Demonstração:**

$$var(x) = E(x^2 - 2\mu_x x + \mu_x^2) \quad (1.40)$$

$$= E(x^2) - 2\mu_x E(x) + \mu_x^2 \quad (1.41)$$

$$= E(x^2) - 2\mu_x \mu_x + \mu_x^2 \quad (1.42)$$

$$= E(x^2) - \mu_x^2 \quad (1.43)$$

$$= E(x^2) - (E(x))^2 \quad (1.44)$$

**Obs:**  $E(x^2) \neq (E(x))^2$

**Propriedades** Considerando  $a, b \in \mathbb{R}$ , constantes:

(a)

$$Var(ax) = a^2 Var(x)$$

**Obs:**  $Var(-x) = Var(x)$

(b) Se  $x = a$ , então:

$$Var(x) = Var(a) = 0$$

(c)

$$Var(x \pm a) = Var(x)Var(a) = Var(x)$$

(d) Se  $a, b$  são constantes,

$$\begin{aligned} Var(ax + \pm + b) &= a^2 Var(x) + Var(b) \\ &= a^2 var(x) \end{aligned}$$

(e) Se  $x$  e  $y$  são duas v.a.'s independentes, então:

$$Var(ax \pm by) = a^2 Var(x) + b^2 Var(y)$$

**Exemplo:** Seja  $x$  uma v.a. com f.d.p dada por:

$$f_x = \begin{cases} \frac{x^2}{3}, & -1 < x < 2 \\ 0, & \text{caso contrário} \end{cases} \quad (1.45)$$

**Encontre :**

- (a)  $E(X)$
- (b)  $Var(X)$
- (c)  $E(4X + 3)$
- (d)  $Var(4X + 3)$

**Resolução :**

(a)

$$\begin{aligned} \mu = E(X) &= \int_{-1}^2 \frac{x \times x^2}{3} dx \\ &= \frac{1}{3} \int_{-1}^2 x^3 dx = \frac{1}{12} x^4 \Big|_{-1}^2 \\ &= \frac{1}{12} (16 - 1) = \frac{15}{12} \end{aligned}$$

(b)

$$\begin{aligned} Var(x) &= E(x^2) - (E(x))^2 \\ E(x^2) &= \int_{-1}^2 x^2 \frac{x^2}{3} dx = \frac{1}{3} \int_{-1}^2 -12x^4 dx \\ &= \frac{1}{15} x^5 \Big|_{-1}^2 = \frac{1}{15} (32 + 1) = \frac{33}{15} \\ Var(x) &= \frac{33}{15} - \left( \frac{15}{12} \right)^2 = 0,6375 \end{aligned}$$

(c)

$$E(4x + 3) = 4E(x) + 3 = 8$$

Obs:  $E(ax) = a^2 \text{var}(x)$ 

(d)

$$\text{Var}(4x + 3) = 16\text{Var}(x) = \frac{51}{80} \times 16 = 10,2$$

## Capítulo 2

# Principais Modelos Probabilísticos

### 2.1 Modelos Discretos

#### 2.1.1 Distribuição Uniforme Discreta

A v.a. assume cada um de seus valores com igual probabilidade.

**Definição:** A v.a. discreta  $X$ , assumindo valores  $x_1, x_2, \dots, x_k$  tem distribuição uniforme se, e somente se, sua f.m.p. é definida por:

$$p(x) = P(X = x) = \begin{cases} \frac{1}{k}, & x = x_1, x_2, \dots, x_k \\ 0, & \text{caso contrário} \end{cases} \quad (2.1)$$

**Notação:**  $X \sim U_d(k)$  A média e variância de  $x$  é:

$$\mu_x = E(x) = \sum_{x \in R_x} x_i P(X = x_i) \quad (2.2)$$

$$= \sum_{x \in R_x} x_i \frac{1}{k} = \frac{1}{k} \sum_{x_i \in R_x} x_i$$

$$Var(x) = E(X^2) - (E(X))^2 \quad (2.3)$$

$$= \sum_{x_i \in R_x} (x_i - \mu_x)^2 \times p(X = x_i)$$

$$= \frac{1}{k} \left( \sum_{i=1}^k x_i^2 - \frac{(\sum_{i=1}^k x_i)^2}{k} \right)$$

**Exemplo:** Seja  $x$  uma v.a. que indica o  $n^\circ$  de pontos marcados na face superior de um dado quando ele é lançado. Portanto, temos uma

distribuição uniforme discreta, cuja f.m.p. é dada por:

$$p(x) = P(X = x) = \begin{cases} \frac{1}{6}, & x = 1, 2, 3, 4, 5, 6 \\ 0, & \text{caso contrário} \end{cases} \quad (2.4)$$

E o  $E(x)$  é:

$$\mu_x = E(x) = \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) \quad (2.5)$$

$$= \frac{1}{6}21 = \frac{7}{2} = 3,5 \quad (2.6)$$

E a  $Var(x)$  é:

$$E(x^2) = \frac{1}{6}(1^2 + 2^2 + \dots + 6^2) \quad (2.7)$$

$$= \frac{91}{6} = 15,17 \quad (2.8)$$

$$var(x) = \frac{91}{6} - \left\{\frac{7}{2}\right\}^2 = \frac{105}{36} = 2,92 \quad (2.9)$$

### 2.1.2 Distribuição Bernoulli

Considere uma v.a.  $x$  que assume apenas dois valores 1, se ocorrer sucesso, 0, se ocorrer fracasso. Indicaremos por  $p$  a probabilidade de sucesso, isto é  $P(\text{Sucesso}) = P(x = 1) = p$ .

**Definição:** A v.a. discreta  $x$  que assume apenas valores 0 ou 1 tem Distribuição Bernoulli se, somente se, sua f.m.p. é definida por:

$$p(x) = P(X = x) = \begin{cases} p^x(1-p)^{1-x}, & x = 0, 1, \quad 0 < p < 1 \\ 0, & \text{caso contrário} \end{cases} \quad (2.10)$$

**Notação:**  $X \sim Ber(p)$

**Exemplos:**

$$p(x) = \left(\frac{2}{5}\right)^x \left(1 - \frac{2}{5}\right)^{1-x}, \quad x = 0, 1$$

$$p(x) = \left(\frac{7}{8}\right)^x \left(1 - \frac{7}{8}\right)^{1-x}, \quad x = 0, 1$$

De forma similar, podemos apresentar  $p(x)$  por:

x	0	1
$P(X = x)$	$1 - p$	$p$

x	0	1
$P(X = x)$	$\frac{5}{6}$	$\frac{1}{6}$

A média de  $x$  é:

$$\mu_x = E(x) = p \quad (2.11)$$

e a variância de  $x$  é:

$$\sigma^2 = \text{var}(x) = p(1 - p) \quad (2.12)$$

**Exemplo:** Suponha o lançamento de um dado perfeito e o interesse é ocorrer a face 3.

$$X = \begin{cases} 1, & \text{se ocorrer a face 3} \\ 0, & \text{caso contrário} \{1, 2, 4, 5, 6\} \end{cases}$$

Cuja f.m.p. é dada por:

$$p(x) = P(X = x) = \begin{cases} \frac{1}{6}(1 - \frac{1}{6})^{1-x}, & x = 0, 1 \\ 0, & \text{caso contrário} \end{cases} \quad (2.13)$$

$$X \sim \text{Ber}(\frac{1}{6})$$

A média de  $x$  é:

$$\mu_x = (X) = p = \frac{1}{6}$$

E a variância de  $x$  é:

$$\sigma^2 = \text{var}(x) = p(1 - p) = \frac{1}{6} \times \frac{5}{6} = \frac{5}{36}$$

### 2.1.3 Distribuição Binominal

Considere  $M$  ensaios de Bernoulli independentes, todos com a mesma probabilidade de sucesso  $p$ . A v.a. que conta o número de sucessos nos  $M$  ensaios de Bernoulli é denominada v.a. binomial com parâmetro  $M$  e  $p$ .

**Definição:** A v.a. discreta  $x$ , correspondente ao  $n^o$  de sucesso em  $M$  ensaios independentes de Bernoulli, tem distribuição binomial se, e somente se, sua f.m.p. é definida por:

$$p(x) = P(X = x) = \begin{cases} \binom{M}{x} p^x (1 - p)^{M-x}, & x = 0, 1, \dots, M, \quad 0 < p < 1 \\ 0, & \text{Caso contrário} \end{cases} \quad (2.14)$$

Notação:  $X \sim \text{Bin}(M, p)$

**Obs:**  $\binom{M}{x} = \frac{M!}{x!(M-x)!}$

Temos que:


$$\mu_x = E(X) = Mp \quad (2.15)$$

$$\sigma^2 = \text{var}(x) = Mp(1 - p) \quad (2.16)$$

**Exemplo :** Considere uma linha de produção, onde 3 peças são selecionadas aleatoriamente e são classificadas como defeituosas (D) ou não-defeituosas(N).

$X_1, X_2, X_3$  são variáveis aleatórias que assumem 1 se a peça for não-defeituosa e 0 caso contrário. A probabilidade da peça ser não-defeituosa é  $p$  e , conseqüentemente, a probabilidade da peça ser defeituosa é  $1 - p$ . Estamos interessados na distribuição de:  $Y = X_1 + X_2 + X_3$

$$X_1 = \begin{cases} 1, & \text{Peça não deituosa} \\ 0, & \text{Peça deituosa} \end{cases}$$





	$X_1$	$X_2$	$X_3$	$Y = X_1 + X_2 + X_3$	$P(Y = y)$
DNN	0	1	1	2	$p^2(1-p)$
DND	0	1	0	1	$p(1-p)^2$
DDN	0	0	1	1	$p(1-p)^2$
DDD	0	0	0	0	$(1-p)^3$
NNN	1	1	1	3	$p^3$
NND	1	1	0	2	$p^2(1-p)$
NDN	1	0	1	2	$p^2(1-p)$
NDD	1	0	0	1	$p(1-p)^2$

Abaixo estão os possíveis resultados do experimento:

y	0	1	2	3
$P(Y = y)$	$(1-p)^3$	$3p(1-p)^2$	$3p^2(1-p)$	$p^3$

Ou seja,

$$p(y) = P(Y = y) = \begin{cases} \binom{3}{y} p^y (1-p)^{3-y}, & y = 0, 1, 2, 3 \\ 0, & \text{Caso contrário} \end{cases}$$

**Exemplo :**

Uma rede varejista compra certo tipo de equipamento eletrônico. O fabricante indica que a taxa de equipamentos em perfeito estado é 97%.

- Seleciona-se ao acaso 20 itens. Qual a probabilidade de haver pelo menos um item defeituoso nesses 20?
- Seleciona-se aleatoriamente 20 itens em cada 10 carregamentos, qual a probabilidade de haver 3 carregamentos com pelo menos um item defeituoso?

$p$  taxa de equipamentos em perfeito estado

$$p = 0,97$$

$y$ :  $n^o$  de equipamentos em perfeito estado.

$$y \sim \text{Binom}(20; 0,97)$$

**Resolução :**

(a)

$$M = 20 \text{ itens}$$

$p$  : Probabilidade de pelo menos um item defeituoso.

$$p = 0,03$$

$$X_i = \begin{cases} 1, & \text{se o equipamento é defeituoso} \\ 0, & \text{c.c.} \end{cases}$$

$$X \sim \text{Binom}(20 : 0,03) \quad x = 1, 2, 3, 4, 5, \dots, 20$$

$$Y = X_1 + X_2 + \dots + X_{20}$$

$$\begin{aligned} P(Y \geq 1) &= 1 - P(Y < 1) \\ &= 1 - P(Y = 0) \end{aligned}$$

$$P(Y = 0) = \binom{20}{0} (0,03)^0 (1 - 0,03)^{20-0} = 0,5438$$

$$\begin{aligned} P(Y \geq 1) &= 1 - 0,5438 \\ &= 0,4562 \end{aligned}$$

Ou, resolvendo pela v.a.  $Y$ , temos:

$$X_i = \begin{cases} 1, & \text{se o equipamento for perfeito} \\ 0, & \text{se o equipamento for defeituoso} \end{cases}$$

$$\begin{aligned} P(Y \leq 19) &= 1 - P(Y > 19) \\ &= 1 - P(Y = 20) \end{aligned}$$

$$\begin{aligned} P(y = 20) &= \binom{20}{20} 0,97^{20} (1 - 0,97)^{20-20} \\ &= 0,5438 \end{aligned}$$

$$\begin{aligned} P(y \leq 19) &= 1 - 0,5339 \\ &= 0,4562 \end{aligned}$$

(b)

10 Carregamentos  
 20 itens são selecionados  
 $Y$  :  $n^o$  de carregamento com pelo menos um item defeituoso  
 $M = 10$   
 $Y = 0, 1, 2, \dots, 10$   
 $p$  : Proporção de ter pelo menos um item defeituoso em um carregamento  
 $p = 0,4562$   
 $Y \sim B(10 : 0,4562)$

$$P(Y = 3) = \binom{10}{3} (0,4562)^3 (1 - 0,4562)^{10-3} = 0,1602$$

#### 2.1.4 Distribuição Geométrica

Considere uma sequência de ensaios Bernoulli independentes em probabilidade de sucesso  $p$  ( $0 < p < 1$ ). Seja a v.a.  $x$  o  $n^o$  de fracassos até a ocorrência do 1º sucesso. Similarmente, a v.a.  $x$  pode ser vista como o  $n^o$  de ensaios que precedem o primeiro sucesso.

**Definição :** A v.a.  $x$  tem distribuição geométrica se, e somente se, sua f.m.p. é definida por:

$$p_x(x) = P(X = x) = \begin{cases} p(1-p)^x, & x = 0, 1, 2, \dots \quad 0 < p < 1 \\ 0, & \text{caso contrário} \end{cases} \quad (2.17)$$

Notação:  $X \sim Geo(p)$

Temos que:

$$\mu_x = E(x) = \frac{1-p}{p} \quad \text{e a} \quad (2.18)$$

$$\sigma^2 = var(x) = \frac{1-p}{p^2} \quad (2.19)$$

Similarmente, a variável aleatória  $Y$  pode ser vista como o  $n^o$  de ensaios que precedem o primeiro sucesso assim,  $Y$  tem a distribuição geométrica com f.m.p. dada por:

$$p_y(y) = P(Y > y) = \begin{cases} (1-p)^{y-1} & p, y = 1, 2, \dots \\ 0, & \text{Caso contrário} \end{cases} \quad (2.20)$$

Neste caso, a v.a.  $Y$  pode ser vista como  $Y = X + 1$  e, consequentemente, o valor esperado de  $y$  é:

$$\mu_{y} = E(Y) = E(X + 1) = E(X) = E(X) + 1 = \frac{1}{p} \quad (2.21)$$

E a variância de  $Y$  é:

$$\sigma_y^2 = \text{var}(Y) = \text{var}(X + 1) = \text{var}(X) = \frac{1 - p^2}{p} \quad (2.22)$$

**Exemplo :** Um pesquisador está realizando um experimentos químicos independentes e sabe que a probabilidade de que cada cada experimento apresnete uma reação positiva é  $0,3$ . Qual é a probabilidade de que menos de 3 reações negativas ocorram antes da primeira positiva?

$x$ :  $n^o$  de ocorrência positiva

$$x = \begin{cases} 1, & \text{se a reação positiva} \\ 0, & \text{caso contrário} \end{cases}$$

$$P(x = 1) = p = 0,3$$

$X$  :  $n^o$  de reações negativas até a ocorrência de uma positiva

$$Y \sim \text{Geo}(0,3)$$

$$P(X < 3) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$P(X = 0) = (1 - 0,3)^0 \times 0,3 = 0,3$$

$$P(X = 1) = (1 - 0,3)^1 \times 0,3 = 0,21$$

$$P(X = 2) = (1 - 0,3)^2 \times 0,3 = 0,147$$

$$P(X < 3) = 0,3 + 0,21 + 0,147 = 0,657$$

Ou ainda,

$Y$  :  $n^o$  de ensaios até a ocorrência de reação positiva

$$R_y = \{1, 2, 3, \dots\}$$

$$P(Y < 4) = P(Y \leq 3) = P(Y = 1) + P(Y = 2) + P(Y = 3)$$

$$P(Y = y) = p(1 - p)^{y-1} \quad y = 1, 2, \dots$$

### 2.1.5 Distribuição Binomial Negativa

Considere ensaios independentes de Bernoulli ( $p$ ) e definimos  $X$  como o  $n^o$  de fracassos anteriores ao  $r$ -ésimo sucesso.

**Definição :** A v.a.  $x$  tem distribuição Binomial negativa se, e somente se, sua f.m.p. é definida por:

$$p(x) = P(X = x) = \begin{cases} \binom{x+r-1}{r-1} p^r (1-p)^x, & x=0,1,2,\dots \\ 0, & \text{caso contrário} \end{cases} \quad (2.23)$$

Notação:  $X \sim BN(r, p)$

Temos que:

$$\mu_x = E(x) = \frac{r(1-p)}{p} \quad (2.24)$$

$$\sigma^2 = var(x) = \frac{1-p}{p^2} \quad (2.25)$$

**Observações :**

1. Note que se  $r = 1$ , temos o modelo geométrico.
- 2.

$$\binom{x+r-1}{r-1} = \binom{x+r-1}{x}$$

A Binomial Negativa pode ser definida como o  $n^o$  de ensaios necessários para a obtenção do  $r$ -ésimo sucesso. Formando  $y = x + r$  temos a quantidade desejada e seus valores variam de  $r$  em diante. Assim sendo  $Y$  o  $n^o$  de ensaios até a obtenção de  $r$  sucessos, temos:

$$p(y) = p(Y = y) = \begin{cases} \binom{y-1}{r-1} p^r (1-p)^{y-r}, & y = r, r+1, \dots \\ 0, & \text{caso contrário} \end{cases} \quad (2.26)$$

**Exemplo :** Em uma serie do campeonato de basquete, o time que ganhar quatro em sete jogos sera o vencedor. Suponha que o time  $A$  tenha probabilidade de 55% de ganhar de  $B$  e que  $A$  e  $B$  se enfrentaram em uma serie de sete jogos. Qual a probabilidade de que  $A$  vença a serie em 6 jogos?

$X$  : O número de derrotas de  $A$  até que  $A$  ganhe 4 partidas

$$X \sim BN(r = 4, p = 0,55)$$

$$P(X = 2) = \binom{2+4-1}{4-1} 0,55^4 \times 0,45^2 = 0,1853$$

Ou, de maneira similar, temos:

$Y$  : número de partidas até que  $A$  vença o campeonato

$$P(Y = 6) = \binom{6-1}{4-1} 0,55^4 \times 0,45^{6-4} = 0,1853$$

### 2.1.6 Distribuição Hipergeométrica

Considere um conjunto de  $n$  objetos dos quais  $m$  são do tipo  $I$  e  $(n-m)$  são do tipo  $II$ . Para um sorteio de  $r$  objetos ( $r < n$ ), feitos ao acaso e sem repetição, defina  $X$  como o número de objetos do tipo  $I$  selecionados.

**Definição:** A v.a.  $X$  tem distribuição Hipergeométrica se sua f.m.p. é dada por:

$$P_x(x) = P(X = x) = \frac{\binom{m}{x} \binom{n-m}{r-x}}{\binom{n}{r}}$$

Em que  $x$  (inteiro) é tal que:

$$\max\{0, r - (n - m)\} \leq x \leq \min\{r, m\}$$

**Observação :** Os limites de  $x$  garantem que situações absurdas ocorram.

Temos que:

$$E(X) = r \frac{m}{n}$$

$$Var(x) = \frac{r \times m(n-m)(n-r)}{n^2(n-1)}$$





Figura 2.1:

**Notacao** :  $X \sim H_{geo}(m, n, r)$

**Exemplo** : Considere que em um lote de 20 peças, existam 4 defeituosas. Selecciona-se 5 dessas peças, sem reposicao, qual seria a probabilidade de duas defeituosas terem sido escolhidas?



$X$  :  $N^o$  de peças defeituosas em 5 retiradas

$$P(x = 2) = \frac{\binom{4}{2} \binom{16}{3}}{\binom{20}{5}}$$

$$R_x : \{0, 1, 2, 3, 4\}$$

### 2.1.7 Distribuição de Poisson

É largamente empregada quando se deseja contar o número de eventos de certo tipo que ocorrem em um certo período de tempo ou superfície ou volume.

**Definicao** Uma v.a. tem Distribuição Poisson com parâmetro  $\lambda$ ,  $\lambda > 0$ , se sua f.m.p. é dada por:

$$P_x(x) = P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots \quad (2.27)$$

Notacao:  $X \sim Poi(\lambda)$

Temos que:

$$E(X) = \lambda \quad (2.28)$$

$$Var(x) = \lambda \quad (2.29)$$

**Exemplo** : Uma central telefonica recebe, em média, 5 chamadas por minuto. Supondo que a distribuição de Poisson seja adequada nessa

situação, obtenha a probabilidade de que a central receba no máximo 2 chamadas durante um intervalo de um minuto.

$X$  :  $n^o$  de chamadas recebidas em 1 minuto em uma central telefonica

$$E(X) = \lambda = 5 \text{ chamadas/minuto}$$

$$P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$P(X = 0) = \frac{e^{-5}5^0}{0!} = 0,0067$$

$$P(X = 1) = \frac{e^{-5}5^1}{1!} = 0,0334$$

$$P(X = 2) = \frac{e^{-5}5^2}{2!} = 0,0842$$

Logo,

$$P(X \leq 2) = 0,0067 + 0,0334 + 0,0842 = 0,1243$$

### O processo de Poisson

Suponha que  $\mu$  seja a média de ocorrência do evento de interesse em  $t$  unidades de medida (por exemplo, tempo). Denotamos por  $\lambda$ , a taxa média de ocorrência em uma unidade de medida, como  $\mu = \lambda t$ . Podemos reescrever a f.m.p. por:

$$p_x = P(X = x) = \frac{e^{-\lambda t} (\lambda t)^x}{x!}, \quad x = 0, 1, 2, \dots$$

**Exemplo :** Considere o exemplo anterior e calcule a probabilidade de que a central telefonica receba no máximo duas chamadas em 4 minutos.

$$P(X \leq 2t = 4) = P(X = 0) + P(X = 1) + P(X = 2)$$

$$P(X = 0) = \frac{e^{-5 \times 4} (5 \times 4)^0}{0!} = 2,06 \times 10^{-9}$$

$$P(X = 1) = \frac{e^{-5 \times 4} (5 \times 4)^1}{1!} = 4,12 \times 10^{-8}$$

$$P(X = 2) = \frac{e^{-5 \times 4} (5 \times 4)^2}{2!} = 4,12 \times 10^{-7}$$

$$P(X \leq 2t = 4) = 2,06 \times 10^{-9} + 4,12 \times 10^{-8} + 4,12 \times 10^{-7} = 4,56 \times 10^{-7} \approx 0$$



**Resultados Importantes Resultado 1** : Se  $X_1, X_2, \dots, X_n$  são independentes e  $X_i \sim \text{Poisson}(\lambda_i)$ , então:

$$Y = X_1 + X_2 + \dots + X_n \sim \text{Poisson}(\lambda_1 + \dots + \lambda_n) \quad (2.30)$$

**Resultado 2** : Se  $X \sim \text{Bin}(M, P)$ . com  $m$  grande e  $P$  pequeno, pode-se aproximar a distribuição de  $X$  pela distribuição de Poisson, cujo parâmetro será  $\lambda = M \times P$ .

**Exemplo** : número de gols marcados em  $M = 100$  tentativas.

$$\begin{aligned} P &= 0,05 \quad \therefore X \sim \text{Bin}(100, 0,05) \\ P(X \geq 50) &= P(X = 50) + \dots + P(X = 100) = 1 - \{P(X = 0) + \dots + P(X = 49)\} \\ E(X) &= M \times p = \mu \\ X &\sim \text{Poi}(\lambda = M \times P) \end{aligned}$$

**Exercício** : Em certa instalação industrial, acidentes ocorrem com baixa frequência. Sabe-se que a probabilidade de um acidente ocorrer em um certo dia é 0,005 e que os acidentes são independentes.

- (a) Qual a probabilidade de que em um período de 400 dias haja no máximo 3 dias com acidente? Utilize a aproximação pela distribuição de Poisson.
- (b) Calcule a probabilidade exata do item anterior e compare os resultados.


## 2.2 Modelos Contínuos

### 2.2.1 Distribuição Uniforme

**Definição** : Uma v.a. contínua  $X$  tem distribuição uniforme no intervalo  $(a, b)$ ,  $a, b \in \mathbb{R}$ , se sua f.d.p. é dada por:

$$f_x(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{caso contrário} \end{cases} \quad (2.31)$$

**Notação** :  $X \sim U(a, b)$

Figura 2.2: ilustração da f.d.p de  $X$ 

A f.d.a. é dada por:

$$F_x x = \begin{cases} 0, & \text{se } x < a \\ \frac{x-a}{b-a}, & \text{se } a \leq x < b \\ 1, & \text{se } x \geq b \end{cases} \quad (2.32)$$

$$\begin{aligned} P(X \leq x) &= \int_{(-\infty)}^x f_x(t) dt = \int_a^x \frac{1}{b-a} dt \\ &= \frac{1}{b-a} t \Big|_a^x = \frac{x-a}{b-a} \end{aligned} \quad (2.33)$$

**Exemplo :**

$$\begin{aligned} P(a_1 \leq X \leq b_1) &= F_x(b_1) - F_x(a_1) \\ P(X > a_1) &= 1 - P(X \leq a_1) \\ &= 1 - F_x(a_1) \\ P(X > a_1) &= F_x(b_1) \end{aligned}$$

A média de  $x$  é:

$$E(X) = \frac{a+b}{2}$$

E a variância de  $x$  é:

$$Var(x) = \frac{(b-a)^2}{12}$$

**Exemplo** : Seja  $X$  uma v.a. com distribuição uniforme,  $U(-1/2, 1/2)$ . Calcule:

- (a)  $F_x(x)$
- (b)  $P(-\frac{1}{4} \leq x \leq \frac{1}{4})$
- (c)  $E(x)$  e  $Var(x)$

Sabe-se que:

$$X \sim U\left(-\frac{1}{2}; \frac{1}{2}\right)$$

Assim, a f.d.p. de  $x$  é:

$$f_x(x) = \frac{1}{\frac{1}{2} - \left(-\frac{1}{2}\right)} = 1 \quad -\frac{1}{2} < x < \frac{1}{2}$$

- (a)  $F_x(x) = ?$

$$\begin{aligned} F_x(x) &= P(X \leq x) = \int_{(-\infty)}^{(x)} f(t) dt \\ &= \int_{\left(-\frac{1}{2}\right)}^{(x)} 1 dt = t \Big|_{-\frac{1}{2}}^x \\ &= x + \frac{1}{2} \end{aligned}$$

$$F_x(x) = P(X \leq x) = \begin{cases} 0, & \text{se } x < -\frac{1}{2} \\ x + \frac{1}{2}, & \text{se } -\frac{1}{2} \leq x < \frac{1}{2} \\ 1, & x \geq \frac{1}{2} \end{cases}$$

- (b)

$$\begin{aligned} P\left(-\frac{1}{4} \leq X \leq \frac{1}{4}\right) &= \int_{\left(-\frac{1}{4}\right)}^{\left(\frac{1}{4}\right)} f(t) dt \\ &= x \Big|_{-\frac{1}{4}}^{\frac{1}{4}} = \frac{1}{4} + \frac{1}{4} = \frac{1}{2} \end{aligned}$$

Ou

$$\begin{aligned} P\left(-\frac{1}{4} \leq X \leq \frac{1}{4}\right) &= F_x\left(\frac{1}{4}\right) - F_x\left(-\frac{1}{4}\right) \\ &= \frac{3}{4} - \frac{1}{4} = \frac{1}{2} \end{aligned}$$

(c)


$$\begin{aligned}
 E(X) &= \frac{a+b}{2} \\
 &= \frac{\frac{-1}{2} + \frac{1}{2}}{2} = 0 \\
 Var(x) &= \frac{(b-a)^2}{12} = \frac{\left(\frac{1}{2} + \frac{1}{2}\right)^2}{12} = \frac{1}{12}
 \end{aligned}$$

### 2.2.2 Distribuição Exponencial

**Definição :** Uma v.a. contínua  $X$  tem distribuição exponencial com parâmetro  $\lambda, \lambda > 0$ , se sua f.d.p. é dada por:

$$f_x(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{caso contrário} \end{cases}$$

**Notação :**  $X \sim Exp(\lambda)$



A f.d.a. de  $x$  é:

$$\begin{aligned}
 P(X \leq x) &= \int_{-\infty}^x f_x(t) dt \\
 &= \int_0^x \lambda e^{-\lambda t} dt \\
 &= -e^{-\lambda t} \Big|_0^x = -e^{-\lambda x} + 1 \\
 &= 1 - e^{-\lambda x}
 \end{aligned}$$

$$F_x(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

A média e variância de  $x$  são:

$$E(x) = \frac{1}{\lambda}$$

$$Var(x) = \frac{1}{\lambda^2}$$

**Propriedade :** Se  $X \sim Exp(\lambda)$ , então:

$$P(X > a + b | X > a) = P(X > a)$$

Esta propriedade é conhecida por falta de memória e é a única distribuição contínua que tem essa propriedade.

**Observação :**

Outra parametrização para a distribuição exponencial é:

$$f_x(x) = \frac{1}{2}e^{-\frac{x}{2}}, \quad x \geq 0$$

Ou seja,  $\lambda = \frac{1}{\alpha}$  A média de  $x$  será:

$$E(x) = \alpha$$

E a variância é dada por:

$$Var(x) = \alpha^2$$

**Exemplo:** Seja  $X$  o tempo de vida útil de um fusível que tem distribuição Exponencial com vida média de 100 horas. Qual a probabilidade de um fusível durar mais de 150 horas?

$$X \sim Exp\left(\frac{1}{100}\right)$$

$$\mu = E(x) = \frac{1}{\lambda} = 100 \left( \lambda = \frac{1}{100} \right)$$

$$P(X > 150) = \int_{150}^{\infty} \frac{1}{100} e^{-\frac{1}{100}x} dx = 0,22313$$

Ou

$$P(X > 150) = 1 - P(X \leq 150) =$$

$$1 - \int_0^{150} \frac{1}{100} e^{-\frac{1}{100}x} dx = 0,22313$$

### 2.2.3 Distribuição Normal

É a distribuição mais importante dos modelos probabilísticos. É também conhecida como distribuição gaussiana. Sua representação gráfica é conhecida por curva em forma de sino.


**Definição:** Uma v.a. contínua  $X$  tem Distribuição normal com parâmetro  $\mu$  (média) e  $\sigma^2$  se sua f.d.p. é dada por:

$$f_x(X) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-1}{2\sigma^2}(x-\mu)^2} \quad -\infty < x < \infty \quad (2.34)$$

$$\text{Com} \quad -\infty < \mu < \infty, \quad \sigma^2 > 0 \quad (2.35)$$

**Notação:**  $X \sim N(\mu; \sigma^2)$

Uma ilustração gráfica da sua f.d.p. é:



A média e variância de  $x$  são:

$$E(x) = \mu$$

$$Var(x) = \sigma^2$$

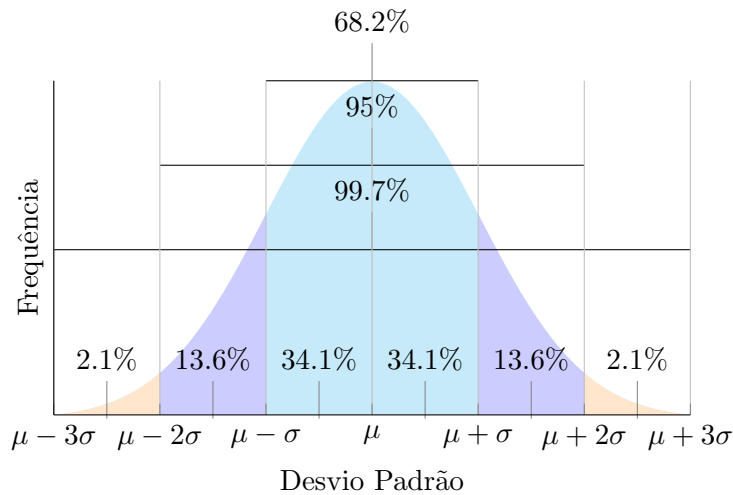
**Propriedades:** A distribuição é simétrica em relação à média. Isto é:

$$f(\mu - x) = f(\mu + x), \quad \forall x \in \mathbb{R} \quad (2.36)$$

Como a área total sob a curva é igual a 1, à esquerda e à direita de  $\mu$ , a área é igual a 0,5.

$$\begin{aligned}
 P(\mu - \sigma \leq X \leq \mu + \sigma) &= 0,6896 \\
 P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) &= 0,9546 \\
 P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) &= 0,9973
 \end{aligned}$$

Ilustrando:



A f.d.a. de uma v.a.  $X \sim N(\mu, \sigma^2)$  é:

$$F_x(X) = P(X \leq x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{-1}{2\sigma^2}(t-\mu)^2} dt$$

Cuja integral não tem solução analítica. Assim, calculamos suas probabilidades com auxílio de tabelas.

**Definição :** Se  $X \sim N(\mu; \sigma^2)$ , então a v.a.  $Z$  é definida por:

$$Z = \frac{X - \mu}{\sigma} \quad (2.37)$$

Terá a distribuição normal com média 0 e variância 1. Ou seja,  $Z \sim N(0, 1)$ .

Essa distribuição é conhecida como distribuição normal-padrão ou reduzida.

### Cálculo de probabilidades


**Exemplo** Uso da tabela normal padrão:

Seja  $Z \sim N(0, 1)$  calcule:

- (a)  $P(0 \leq Z \leq 1,65)$
- (b)  $P(Z \leq 0,5)$
- (c)  $P(Z < -1,57)$
- (d)  $P(-0,65 \leq Z \leq 0,5)$
- (e)  $P(0,8 \leq Z < 1,4)$
- (f)  $P(0 \leq Z \leq z) = 0,4753$
- (g)  $P(Z < z) = 0,05$

Resolva:

- (a)  $P(0 \leq Z \leq 1,65)$




$$P(0 \leq Z \leq 1,65) = 0,45053$$

Ou:

$$\begin{aligned}
 P(0 \leq Z \leq 1,65) &= P(Z < 1,65) - P(Z \leq 0) \\
 &= P(z < 1,65) - 0,5 \\
 &= 0,9505 - 0,5 = 0,4505
 \end{aligned}$$

- (b)  $P(Z < 0,5)$






$$\begin{aligned}
 P(Z < 0,5) &= 0,5 + P(0 \leq Z \leq 0,5) \\
 &= 0,5 + 0,19146 \\
 &= 0,69146
 \end{aligned}$$


Ou

$$P(Z < 0,5) = 0,6915$$

(c)  $P(Z < -1,57)$



Ou equivalentemente:




$$\begin{aligned}
 P(Z < -1,57) &= P(Z > 1,57) \\
 &= 0,5 - P(0 \leq Z \leq 1,57) \\
 &= 0,5 - 0,44179 \\
 &= 0,0582
 \end{aligned}$$

Ou


$$P(Z < -1,57) = 0,0582$$

(d)  $P(-0,65 \leq Z \leq 0,65)$




$$\begin{aligned}
 P(-0,65 \leq Z \leq 0) &= P(-0,65 \leq Z \leq 0) \\
 &= 2P(0 \leq Z \leq 0,65) \\
 &= 2 \times 0,24215 \\
 &= 0,4843
 \end{aligned}$$

$$P(-0,65 \leq Z \leq -0,65) = P(Z < 0,65) - P(Z < -0,65)$$




(e)

$$\begin{aligned} P(0,8 < z < 1,4) &= P(0 \leq Z \leq 1,4) - P(0 \leq Z \leq 0,8) \\ &= 0,41924 - 0,28814 \end{aligned}$$

(f)  $P(0 \leq Z \leq z) = 0,4753$ 

$$z = 1,965$$

(g)  $P(Z < z) = 0,05$



$$z = -1,645$$


**Exemplo:** Seja  $X \sim N(90, 100)$

**Determine :**

- (a)  $P(80 < x < 100)$
- (b)  $P(x \geq 90)$
- (c)  $P(60 \leq x \leq 75)$

**Resolução :**

- (a)  $P(80 < x < 100)$




$$Z = \frac{X - \mu}{\sigma}$$

$$z_1 = \frac{80 - 90}{10} = -1$$

$$z_2 = \frac{100 - 90}{10} = 1$$

$$P(80 < X < 100) = P(-1 < Z < 1)$$




$$P(-1 < Z < 1) = 2 \times P(0 < Z < 1)$$

$$= 2 \times 0,34134$$



$$= 0,6826$$

(b)  $P(x \geq 90)$



$$\begin{aligned}
 P(x \geq 90) &= P(Z \geq \frac{90 - 90}{10}) \\
 &= P(Z \geq 0) = 0,5
 \end{aligned}$$

(c)  $P(60 \leq x \leq 75)$



$$\begin{aligned}
 &P(60 \leq X \leq 75) \\
 &= P(\frac{60 - 90}{10} \leq Z \leq \frac{75 - 90}{10}) \\
 &= P(-3 \leq Z \leq 1,5)
 \end{aligned}$$

$$\begin{aligned}
 &P(-3 < Z < 1,5) \\
 &= P(Z < 1,5) - P(Z < -3) \\
 &= 0,0668 - 0,0013 \\
 &= 0,0655
 \end{aligned}$$

**Exemplo:** Seja  $X \sim N(50; 10^2)$

**Determine:** (a)  $P(|X - 50| < 10)$

(b)  $P(\mu - a \leq X \leq \mu + a) = 0,9$



(c)  $P(K < X < 70) = 0,8185$

(d)  $P(K < x < 75) = 0,3031$

**Resolução:** (a)  $P(|X - 50| < 10)$

$$\begin{cases} X - 50 < 10 \Rightarrow X < 60 \\ -(X - 50) < 10 \Rightarrow X > 40 \end{cases}$$


$$\begin{aligned} P(|X - 50| < 10) &= P(40 < X < 60) \\ &= P\left(\frac{40 - 50}{10} < Z < \frac{60 - 50}{10}\right) \\ &= P(-1 < Z < 1) \end{aligned}$$



$$\begin{aligned}
 P(-1 < Z < 1) &= 2 \times P(0 < Z < 1) \\
 &= 2 \times 0,34124 \\
 &\simeq 0,68
 \end{aligned}$$

$$(b) \quad P(\mu - a \leq X \leq \mu + a) = 0,9$$


$$\begin{aligned}
 P(50 - a \leq X \leq 50 + a) &= 0,9 \\
 P\left(\frac{(50 - a) - 50}{10} \leq Z \leq \frac{(50 + a) - 50}{10}\right) &= 0,9 \\
 P\left(\frac{-a}{10} \leq Z \leq \frac{a}{10}\right) &= 0,9
 \end{aligned}$$



$$\begin{aligned}
 P\left(\frac{-a}{10} \leq Z \leq \frac{a}{10}\right) &= 2 \times P\left(0 \leq Z \leq \frac{9}{10}\right) = 0,9 \\
 P\left(0 \leq Z \leq \frac{a}{10}\right) &= 0,45 \\
 \frac{a}{10} &= 1,645 \\
 a &= 16,5
 \end{aligned}$$

$$(c) \quad P(K < X < 70) = 0,8185$$





$$P\left(\frac{K-50}{10} < Z < \frac{70-50}{10}\right) = 0,8185$$

$$P\left(\frac{K-50}{10} < Z < 2\right) = 0,8185$$

$$P\left(\frac{K-50}{10} < Z < 2\right) = 0,8185$$

$$P\left(\frac{K-50}{10} < Z < 0\right) + P(0 < Z < 2) = 0,8185$$

$$P\left(\frac{K-50}{10} < Z < 0\right) = 0,8185 - 0,47725$$

$$P\left(\frac{K-50}{10} < Z < 0\right) = 0,3413$$

$$\frac{-(K-50)}{10} = 10$$

$$K = 40$$

(d)  $P(K < x < 75) = 0,3031$

Temos o caso da tabela 1 caso  $P(50 < X < 75) > 0,3031$ .

Do contrário, se  $P(50 < X < 75) < 0,3031$ , temos o caso do tabela 2.

$$\begin{aligned} & P(50 < X < 75) \\ &= P\left(\frac{50-50}{10} < Z < \frac{75-50}{10}\right) \\ &= P(0 < Z < 2,5) = 0,49379 \end{aligned}$$

$$\begin{aligned} & P(K < X < 75) = 0,3031 \\ &= P\left(\frac{K-50}{10} < Z < 2,5\right) = 0,3031 \end{aligned}$$

$$P(0 < Z < 2,5) - P(0 < Z < \frac{k-50}{k}) = 0,3031$$

$$0,49379 - 0,3031 = P(0 < Z < \frac{k-50}{10})$$

$$P(0 < Z < \frac{\overbrace{k-50}^{0,495}}{10}) = 0,19069$$

$$\frac{K-50}{10} = 0,495 \Rightarrow K = 4,95 + 50$$

$$K = 54,95$$

### Distribuição da Combinação linear de v.a.s normais independentes

Sejam  $X_1, X_2, \dots, X_n$  e  $n$  v.a.s tais que:

$$X_i \sim N(\mu; \sigma^2) \quad \text{para } i = 1, 2, \dots, n$$

Considere  $Y = \sum_{i=1}^n X_i = X_1 + \dots + X_n$ , temos que:

$$\begin{aligned} E(Y) &= E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) \\ &= \sum_{i=1}^n \mu = n \times \mu \end{aligned}$$

Ou

$$\begin{aligned} E(Y) &= E\left(\sum_{i=1}^n X_i\right) = E(X_1 + \dots + X_n) \\ &= E(X_1) + E(X_2) + \dots + E(X_n) \\ &= \underbrace{\mu + \mu + \dots + \mu}_n = n \times \mu \end{aligned}$$

Assim:

$$\begin{aligned} Var(Y) &= Var\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n Var(X_i) \\ &= \sum_{i=1}^n \sigma^2 = n \times \sigma^2 \end{aligned}$$

Logo,  $Y \sim N(n\mu; n\sigma^2)$ .

Pelas propriedades da distribuição normal, temos que se  $Y \sim N(n\mu; n\sigma^2)$ , a variável reduzida será:

$$Z = \frac{Y - E(Y)}{\sqrt{Var(Y)}} = \frac{Y - n\mu}{\sqrt{n\sigma^2}} \sim N(0, 1)$$

Analogamente, temos a média amostral:

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

Com isso, temos:

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu = \frac{1}{n} \times n \times \mu = \mu \end{aligned}$$

E também:

$$\begin{aligned} Var(\bar{X}) &= Var\left(\frac{\sum_{i=1}^n X_i}{n}\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n Var(X_i) \\ &= \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} \times n \times \sigma^2 \\ &= \frac{\sigma^2}{n} \end{aligned}$$

Logo  $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

A variável reduzida é:

$$\begin{aligned} Z &= \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{x} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \\ &= \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \\ Z &= \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1) \end{aligned}$$

**Exemplo:** O peso de sacos de parafusos empacotados por uma máquina tem média de 50g e desvio-padrão de 2g. Assumindo que o peso tem distribuição normal, qual a probabilidade de que 10 sacos pesem juntos de 490g? Qual a probabilidade de que a média desses 10 sacos sejam no máximo 52g?

(a)

$$\begin{aligned}
X &\sim N(50, 2^2) \\
X_1, X_2, \dots, X_{10} \\
Y &= \sum_{i=1}^n X_i < 490 \\
Y &\sim N(500; 10 \times 2^2) \\
P(Y < 490) &= P(Z < \frac{490 - 500}{\sqrt{40}}) \\
P(Z < -1,58) &= 0,0571
\end{aligned}$$

(b)  $X \leq 52g$ 

$$\begin{aligned}
\bar{X} &= \frac{\sum X_i}{n} \sim N(\mu; \frac{\sigma^2}{n}) \\
\bar{X} &\sim N(50; \frac{2^2}{10}) \\
P(X \leq 52) &= P(Z \leq \frac{52 - 50}{\sqrt{\frac{2}{5}}}) \\
&= P(Z \leq 3,16) \\
P(Z \leq 3,16) &= 0,9992
\end{aligned}$$

## 2.3 Variáveis Aleatórias Bidimensionais

Seja  $X$  e  $Y$  duas variáveis aleatórias quando há interesse na variação conjunta de  $X$  e  $Y$ , estudamos o par  $(X, Y)$  como uma variável aleatória bidimensional. ‘1’

**Definição:** A variável aleatória bidimensional discreta  $(X, Y)$  tem função massa de probabilidade conjunta definida por:

$$P_{x,y} = P(X = x, Y = y) \quad (2.38)$$

A função de distribuição acumulada  $F_{x,y} = P(X \leq x, Y \leq y)$  para  $(x, y)$  valores que  $(X, Y)$  pode assumir.

**Propriedades :**

- (a)  $p_{x,y}(x, y) \geq 0, \quad \forall (x, y).$
- (b)  $\sum_{R_X} \sum_{R_Y} p_{x,y}(x, y) = 1.$

**Exemplo :** Em um processo de inspeção de qualidade, cada peça passa por dois testes e é classificada de acordo com duas variáveis  $X$  e  $Y$ , tais que:

$$X = \begin{cases} 1, & \text{Se a peça passa no primeiro teste} \\ 0, & \text{Se a peça falha no primeiro teste} \end{cases}$$

$$Y = \begin{cases} 1, & \text{Se a peça passa no segundo teste} \\ 0, & \text{Se a peça falha no segundo teste} \end{cases}$$

Segundo a f.m.p. conjunta dada por:

$p_{x,y}$	$Y$	$p_x$	
$X$	0	1	
0	0,1	0,2	0,3
1	0,2	0,5	0,7
$p_y(y)$	0,3	0,7	1

$P(X = 0, Y = 0) = 0,1$ , indica a probabilidade de uma peça selecionada ao acaso falhar no primeiro teste e no segundo teste.

### 2.3.1 Distribuições Marginais

**Definição:** Seja  $(X, Y)$  variável aleatória bidimensional com f.m.p. conjunta  $p_{x,y}(x, y)$ . A probabilidade marginal de  $X$  é  $\sum_{R_Y} p_{x,y}(x, y)$ . A probabilidade marginal de  $Y$  é  $p_y(y) = \sum_{R_x} p_{x,y}(x, y)$ .

**Exemplo:** Considere o exemplo anterior, e obtenha as distribuições marginais.

Marginal de  $X$ :

$$R_x = \{0, 1\}$$

$$\begin{aligned} p_x(0) &= P(X = 0, Y = y) \\ &= P(X = 0, Y = 0) + P(X = 0, Y = 1) = 0,1 + 0,2 = 0,3 \end{aligned}$$

$$\begin{aligned} p_x(1) &= P(X = 1, Y = y) \\ &= P(X = 1, Y = 0) + P(X = 1, Y = 1) = 0,2 + 0,5 = 0,7 \end{aligned}$$

Com isso, temos que a f.m.p. marginal de  $X$  é:

$x$	0	1
$p_x$	0,3	0,7

A f.m.p. marginal de  $Y$  eh dada por:

$y$	0	1
$p_y$	0,3	0,7

**Definicao:** A v.a. bidimensional continua  $(X, Y)$  tem f.d.p. conjunta dada por  $f_{x,y}(x, y)$  e função acumulada  $F_{x,y}(x, y)$ , satisfazendo:

i.

$$f_{x,y} \geq 0, \quad \forall (x, y) \quad (2.39)$$

ii.

$$\int_{R_y} \int_{R_x} f_{x,y}(x, y) dx dy = \int_{R_y} \int_{R_x} f_{x,y}(x, y) dy dx = 1$$

iii.

$$\begin{aligned} F_{X,Y}(x, y) &= P(X \leq x, Y \leq y) \\ &= F_{X,Y}(x, y) = P(X < x, Y \leq y) \\ &= F_{X,Y}(x, y) = P(X \leq x, Y < y) \\ &= F_{X,Y}(x, y) = P(X < x, Y < y) \end{aligned}$$

**Propriedades :**

(a)

$$f_{x,y}(x, y) = \frac{\partial^2}{\partial x \partial y} F_{x,y}(x, y)$$

(b)

$$F_{x,y}(x, y) = \int_{-\infty}^x \int_{-\infty}^y f_{x,y}(x, y) dy dx$$

(c)

$$P(a \leq X \leq b; c \leq y \leq d) = \int_a^b \int_c^d f_{x,y}(x, y) dy dx$$

**Exemplo:** Duas características do desempenho do motor de um foguete são o empuxo ( $X$ ) e a taxa de mistura ( $Y$ ). Suponha que  $(X, Y)$  seja uma v.a. contínua bidimensional com f.d.p. conjunta dada por:

$$f_{x,y}(x, y) = \begin{cases} 2(x + y - 2xy), & 0 \leq x \leq 1, \quad 0 \leq y \leq 1 \\ 0, & \text{c.c.} \end{cases}$$

Calcular a probabilidade:

$$y \in 0, 1$$

$$f_{x,y}(x, y) = 2(x + y - 2xy), \quad x \in 0, 1 \\ y \in 0, 1$$

A marginal de  $X$ :

$$\begin{aligned} f_x(x) &= \int_0^1 2(x + y - 2xy) dy \\ &= 2 \left( xy \Big|_0^1 + xy^2 \Big|_0^1 - xy^2 \Big|_0^1 \right) \end{aligned}$$

$$f_x(x) = 2 \left( x + \frac{1}{2} - x \right) = 1$$

Logo, a f.d.p de  $X$  é:

$$f_x(x) = \begin{cases} 1, & 0 \leq x \leq 1 \\ 0, & \text{c.c.} \end{cases}$$

A marginal de  $Y$ :

$$\begin{aligned} f_y(y) &= \int_0^1 2(x + y - 2xy) dx \\ &= 2 \left( x^2 \Big|_0^1 - yx^2 \Big|_0^1 \right) \\ &= 2 \left( \frac{1}{2} + y - y \right) = 1 \end{aligned}$$

### 2.3.2 Independência Probabilística

Duas v.a.'s  $X$  e  $Y$  são independentes se a sua f.m.p. conjunta (ou f.d.p. conjunta) de  $(X, Y)$  for fatorável no produto das f.m.p. (ou f.d.p. marginais) de  $X$  e  $Y$ , isto é:

$$p_{x,y} = p_x(x) \times p_y(y) \quad (2.40)$$

No caso discreto, e no caso contínuo:

$$f_{x,y}(x, y) = f_x(x) \times f_y(y) \quad \forall (x, y) \quad (2.41)$$

**Exemplo:** Suponha que uma máquina seja ajustada para uma determinada tarefa de manhã e para outra tarefa à tarde. Suponha que o número de vezes que a máquina dá problema de manhã e à tarde sejam representadas por variáveis  $X$  e  $Y$  com f.m.p. conjunta dada por:

$x / y$	0	1	2	$p_x(x)$
0	0,1	0,2	0,2	0,5
1	0,04	0,08	0,08	0,2
2	0,06	0,12	0,12	0,3
$p_Y(y)$	0,2	0,4	0,4	1

Observem que:

$$P(X = 0, Y = 0) = P(x = 0) + P(y = 0) = 0,5 \times 0,2 = 0,1$$

$$P(X = 0, Y = 1) = P(x = 0) + P(y = 1) = 0,5 \times 0,4 = 0,2$$

E assim por diante, para todo  $x$  e  $y$ .

Como esses produtos de probabilidades são satisfeitos, temos que  $X$  e  $Y$  são independentes.

### 2.3.3 Esperança, Covariância, Correlação

**Definição:** Sejam  $x$  e  $y$  v.a.'s com  $E(X) = \mu_x$ ,  $E(Y) = \mu_y$ ,  $Var(X) = \sigma_x^2$  e  $Var(Y) = \sigma_y^2$ . Seja  $p_{x,y}(x, y)$  a f.m.p. conjunta ou  $f_{x,y}(x, y)$  a f.d.p. conjunta de  $x$  e  $y$ . Seja  $h(x, y)$  uma função de  $(X, Y)$ . Definimos o valor esperado de  $h(x, y)$  no caso discreto por:

$$E(h(x, y)) = \sum_{R_x} \sum_{R_y} h(x, y) \times p_{x,y}(x, y) \quad (2.42)$$



E no caso contínuo:

$$E(h(x, y)) = \int_{R_x} \int_{R_y} h(x, y) f_{x,y}(x, y) dy dx \quad (2.43)$$

$$= \int_{R_y} \int_{R_x} h(x, y) f_{x,y}(x, y) dx dy \quad (2.44)$$

Alem disso, definimos para ambos os casos, a covariancia entre  $x$  e  $y$ :

$$\sigma_{x,y} = Cov(X, Y) = E((X - E(X))(Y - E(Y))) \quad (2.45)$$

$$= E(XY) - E(X)E(Y) \quad (2.46)$$

$$= E(XY) - \mu_x \times \mu_y \quad (2.47)$$

A correlacao entre  $x$  e  $y$  eh dada por:

$$\rho_{x,y} = \frac{Cov(X, Y)}{\sqrt{Var(x)} \times \sqrt{Var(y)}} = \frac{\sigma_{x,y}}{\sigma_x \times \sigma_y} \quad (2.48)$$

**Exemplo:** Vamos calcular a Correlacao entre  $X$  e  $Y$  no exemplo anterior (exemplo da maquina).

A f.m.p. conjunta eh:

x / y	0	1	2	$p_x(x)$
0	0,1	0,2	0,2	0,5
1	0,04	0,08	0,08	0,2
2	0,06	0,12	0,12	0,3
$p_Y(y)$	0,2	0,4	0,4	1

$$\rho_{x,y} = \frac{Cov(x, y)}{\sigma_x, \sigma_y}$$

$$Cov(X, Y) = E(XY) - E(X) \times E(Y)$$

$$\begin{aligned} \mu_x &= E(X) = \sum_{R_x} x \times p_x \\ &= 0 \times 0.5 + 1 \times 0.2 + 2 \times 0.3 \\ &= 0.8 \end{aligned}$$

$$\begin{aligned}
\mu_y = E(Y) &= \sum_{R_y} y \times p_y \\
&= 0 \times 0.2 + 1 \times 0.4 + 2 \times 0.4 \\
&= 1.2
\end{aligned}$$

$$\begin{aligned}
E(XY) &= \sum_{R_X} \sum_{R_y} x \times y \times p_{x,y}(x, y) \\
&= 0 \times 0 \times 0.1 + \dots + 2 \times 2 \times 0.12 \\
&= 0.96
\end{aligned}$$

$$\begin{aligned}
Cov(x, y) &= 0.96 - 0.8 \times 1.2 \\
&= 0
\end{aligned}$$

$$\sigma_x^2 - (E(X))^2$$

Como temos:

$$E(X^2) = \sum_{R_x} x^2 \times p_x$$

Logo a  $\rho_{x,y}$  eh:

$$\rho_{x,y} = \frac{0}{x \times \sigma_y} = 0$$

**Resultado :**

**Independencia e correlacao :** Se  $X$  e  $Y$  sao duas v.a.'s independentes, então a correlacao entre  $X$  e  $Y$  eh o 0 ( $\rho_{x,y} = 0$ ).

**Obs:** A volta nao vale. Se  $X$  e  $Y$  sao independentes  $E(XY) = E(X) \times E(Y)$ .

**Resultados :**

Para  $X$  e  $Y$  v.a. 's e  $a, b \in \mathbb{R}$ , constantes:

1.

$$Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$$

2.

$$Var(X - Y) = Var(X) + Var(Y) - 2Cov(X, Y)$$

3. Se  $X$  e  $Y$  são independentes, então:

$$\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y)$$

4.

$$\text{Var}(aX \pm bY) = a^2\text{Var}(X) + b^2\text{Var}(Y) \pm 2ab\text{Cov}(X, Y)$$

5. Se  $X$  e  $Y$  são independentes, então:

$$\text{Var}(aX \pm bY) = a^2\text{Var}(X) + b^2\text{Var}(Y)$$

**Exemplo:** Seja  $(X, Y)$  uma v.a. bidimensional cuja f.d.p. conjunta é dada por:

$$f_{x,y}(x, y) = \begin{cases} 9xy, & 0 < x < y < 1 \\ 0, & \text{c.c.} \end{cases}$$

**Determine:** (a) As marginais de  $X$  e  $Y$

(b)  $P(0 \leq X \leq \frac{1}{2}, 0 \leq Y \leq \frac{1}{2})$

**Resolução:** (a)  $f_x(x) = ?$  e  $f_y(y) = ?$

$$\begin{aligned} f_x(x) &= \int_{R_y} f_{x,y}(x, y) dy \\ &= \int_x^1 9xy dy = \left. \frac{9xy^2}{2} \right|_x^1 \\ &= 4x(1 - x^2) \end{aligned}$$

Então, a marginal de  $x$  é:

$$f_x(x) = \begin{cases} 4x(1 - x^2), & 0 < x < 1 \\ 0, & \text{c.c.} \end{cases}$$

$$\begin{aligned} f_y(y) &= \int_{R_x} f_{x,y}(x, y) dx \\ &= \int_0^y 9xy dx = \left. \frac{9yx^2}{2} \right|_0^y = 4y^3 \end{aligned}$$

Logo, a marginal de  $y$  é:

$$f_y(y) = \begin{cases} 4y^3, & 0 < y < 1 \\ 0, & \text{c.c.} \end{cases}$$

(b)

$$\begin{aligned} P(0 \leq X \leq \tfrac{1}{2}, 0 \leq Y \leq \tfrac{1}{2}) &= \int_0^{\frac{1}{2}} 8xy dy dx \\ &= \int_0^{\frac{1}{2}} \int_0^y 8xy dx dy \\ &= \frac{1}{16} = 0.0625 \end{aligned}$$

## Capítulo 3

# Inferencia Estatística

### 3.1 Introdução

**Objetivo:** Produzir informações sobre dada característica da população na qual estamos interessados, a partir de informações colhidas de uma parte dessa população (amostra).

**Característica:** Variável Aleatória

$$\begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ X &: p_{x,\theta} \text{ ou } f_x(x, \theta) \end{aligned} \tag{3.1}$$

**Situação Prática:**  $\theta$  é desconhecido

**Interesse:** Estimar  $\theta$  (Métodos de Estimação Pontual)

Para isso, considere uma amostra aleatória de  $X$ :

$$X = (X_1, X_2, \dots, X_n)$$

Cada  $X_i$  é independente e tem a mesma distribuição de  $X$ . Associada a uma a.a.  $X$ , temos o vetor de observações:

$$x = (x_1, x_2, \dots, x_n)$$

Com base na a.a. podemos obter uma estatística ou estimador que é função da a.a. :

$$T = T(X_1, X_2, \dots, X_n)$$

As estatísticas mais comuns:

**Média amostral :**

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

**Variancia Amostral :**

$$s^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

**Menor Valor da amostra :**

$$X_{(1)} = \min(X_1, X_2, \dots, X_n)$$

**Maior valor da amostra:**

$$X_{(n)} = \max(X_1, X_2, \dots, X_n)$$

**O problema da inferencia estatística:** fazer afirmações sobre  $\theta(s)$ , parâmetros da população, através da amostra.

Iremos estudar distribuições amostrais de algumas estatísticas.

## 3.2 Distribuições Amostrais

### 3.2.1 Distribuição Amostral da Média

**Estatística:**

(3.2)

**Obs:** Observe que se a população for normal, então terá distribuição exata normal.

Padronizando, obtemos:

$$Z = \frac{\bar{x} - E(\bar{X})}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \quad (3.3)$$

$$= \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \tilde{N}(0, 1) \quad (3.4)$$

**Exemplo :** Uma v.a.  $X$  tem distribuição normal com média 10 e desvio-padrão 3.

- (a) Se  $\bar{X}$  for a média da amostra de 25 elementos retirados dessa população, calcule  $P(a < \bar{X} < 1)$ .

(b) Que tamanho deveria ter a amostra para que  $P(a < \bar{X} < 11 = 0,95)$ ?

(a)  $P(a < X < 11) = ?$

$$n = 25$$

$$\mathbf{X} = (X_1, X_2, \dots, X_{25})$$

$$\bar{X} \tilde{N}(\mu; \frac{\sigma^2}{n})$$

$$\bar{X} \tilde{N}(10; \frac{3^2}{25})$$

$$P(a < \bar{X} < 11) = P\left(\frac{9-10}{\frac{3}{\sqrt{25}}} < Z < \frac{11-10}{\frac{3}{\sqrt{25}}}\right)$$

$$P(-\frac{5}{3} < Z < \frac{5}{3}) = P(-1,67 < Z < 1,67)$$

$$= 2P(0 < Z < 1,67)$$

$$= 2 \times 0,45254 = 0,905$$

(b)

$$\bar{X} \tilde{N}(\mu; \frac{\sigma^2}{n})$$

$$\bar{X} \tilde{N}(10; \frac{3^2}{n})$$

$$P(9 < \bar{X} < 11) = 0,95$$

$$P\left(\frac{9-10}{\frac{3}{\sqrt{n}}} < Z < \frac{11-10}{\frac{3}{\sqrt{n}}}\right) = 0,95$$

$$P\left(\frac{-\sqrt{n}}{3} < Z < \frac{\sqrt{n}}{3}\right) = 0,95$$

$$P\left(0 < Z < \frac{\sqrt{n}}{3}\right) = \frac{0,95}{2} = 0,475$$

$$z = 1,96$$

$$\frac{\sqrt{n}}{3} = 1,96$$

$$n = (5,88)^2$$

$$n = 34,574$$

$$n = 35$$

### 3.2.2 Distribuição Amostral para a Proporção

Seja  $X$  uma v.a. definida da seguinte maneira:

$$X = \begin{cases} 1, & \text{se ocorre sucesso(interesse)} \\ 0, & \text{se ocorre fracasso} \end{cases} \quad (3.5)$$

$X$  distribuição de Bernoulli. Logo:

$$\begin{aligned} E(X) &= \mu = p \\ \text{Var}(X) &= \sigma^2 = p(1-p) \end{aligned}$$

Considere uma a.a.  $\mathbf{X} = (X_1, \dots, X_n)$  da v.a.  $X$  e o interesse é a proporção de indivíduos/elementos que possui a característica de interesse (sucesso),  $\tilde{p}$ . Isto é:

$$\tilde{p} = \frac{\sum_{i=1}^n X_i}{n} = \bar{X} \quad (3.6)$$

Observe que cada  $X_i, i = 1, \dots, n$ , tem distribuição Bernoulli e são independentes. Pelo TCL,  $\tilde{p}$  terá distribuição aproximadamente normal com média  $\mu = p$  e variância:

$$\begin{aligned} \frac{\sigma^2}{n} &= \frac{p(1-p)}{n} \\ \tilde{p} &\sim N\left(p, \frac{p(1-p)}{n}\right) \end{aligned}$$

Padronizando, temos:

$$Z = \frac{\tilde{p} - E(\tilde{p})}{\sqrt{\text{var}(\tilde{p})}} = \frac{p - \tilde{p}}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1)$$

#### Exemplo :

Um procedimento de controle de qualidade foi planejado para garantir um máximo de 10% de itens defeituosos na produção. Supondo que a produção esteja sob controle ( $p = 0,1$ ) e que os itens sejam vendidos em caixas com 100 unidades, qual a probabilidade de que uma caixa:

- (a) Tenha mais do que 10% de defeituosos.
- (b) Não tenha itens defeituosos



$X$ : numero de pecas defeituosas a cada venda

$$X \sim \text{Ber}(p) \quad p = 0,1$$

$$n = 100 \quad (X_1, X_2, \dots, X_{100})$$

$$E(X) = \mu = p = 0,1$$

$$\text{Var}(X) = \sigma^2 = p(1-p) = 0,1 \times 0,9 = 0,09$$

$$(a) \quad 10\% \text{ de } 100 = 10$$

$$\begin{aligned} P\left(\sum_{i=1}^{100} X_i > 10\right) &= P(\tilde{p} > 0,1) \\ &\quad \tilde{p} \sim N\left(0,1; \frac{0,09}{100}\right) \\ P(\tilde{p} > 0,1) &= P\left(Z > \frac{0,1 - 0,1}{\frac{\sqrt{0,09}}{100}}\right) \\ &= P(Z > 0) = 0,5 \end{aligned}$$

$$(b) \quad P\left(\sum_{i=1}^{100} X_i = 0\right) = P(\tilde{p} = 0) \approx 0$$

### 3.3 Fix me

#### 3.3.1 Eficiencia

**Definicao** Considere dois estimadores  $T_1(x) = \tilde{\theta}_1$  e  $T_2(x) = \tilde{\theta}_2$ , nao-viciados para um parametro  $\theta$ . Dizemos que  $\theta_1 = T_1(x)$  eh mais eficiente que  $\tilde{\theta}_2 = T_2(x)$  se  $\text{Var}(T_1(x)) < \text{Var}(T_2(x))$ .

#### 3.3.2 Consistencia

Seja  $T_n(x)_{n \geq 1}$  uma sequencia de estimadores de  $\theta$ :

$$T_1(x); T_2(x); T_3(x); \dots$$

**Definicao** a sequencia  $T_n_{n \geq 1}$  eh definida ser uma sequencia consistente de estimadores de  $\theta$  se, e somente se, para todo  $\epsilon > 0$  satisfaz:

$$\lim_{n \rightarrow \infty} P(|T_n - \theta| \geq \epsilon) = 0$$

**Obs:**  $\lim_{n \rightarrow \infty} P(|T_n - \theta| < \epsilon) = 1$  Em geral, para verificar se um estimador eh consistente, utilizamos a desigualdade de Chebyshev que diz:

$$P(|T_n - \theta| \geq \epsilon) \leq \frac{\text{Var}(T_n(x))}{\epsilon^2}$$

**Proposicao** : Uma sequencia  $T_n(x)_{n \geq 1}$  de estimadores de  $\theta$  eh consistente se:

$$\lim_{n \rightarrow \infty} E(T_n(x)) = \theta$$

E

$$\lim_{n \rightarrow \infty} Var(T_n(x)) = 0$$

**Exemplo** Seja  $X = (X_1, X_2, \dots, X_n)$  uma a.a. da v.a.  $X$  com distribuicao  $N(\mu, \sigma^2)$ . Considere os estimadores de  $\mu$  e  $\sigma^2$ , respectivamente,  $\tilde{\mu} = \bar{X}$  e  $\tilde{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$ . Calcule os vicios para estes estimadores.

Para  $\mu$ :

$$\beta_{\mu}(\tilde{\mu}) = \beta_{\mu}(\bar{X}) = E(\bar{X}) - \mu$$

Obtendo o  $E(\bar{X})$ :

$$E(\bar{X}) = E\left(\frac{\sum_{i=1}^n X_i}{n}\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu$$

Logo,

$$\beta_{\mu}(\bar{X}) = \mu - \mu = 0$$

Portanto,  $\bar{X}$  eh um estimador nao-viciado (nao-viesado).

Para  $\sigma^2$

$$\beta_{\sigma^2} = E(\tilde{\sigma}^2) - \sigma^2$$

Obtendo o  $E(\tilde{\sigma}^2)$  :

$$\begin{aligned} E(\tilde{\sigma}^2) &= E\left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}\right) \\ &= \frac{1}{n} E\left(\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right) \\ &= \frac{1}{n} E\left(\sum_{i=1}^n X_i^2 - \sum_{i=1}^n 2X_i\bar{X} + \sum_{i=1}^n \bar{X}^2\right) \\ &= \frac{1}{n} E\left(\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \end{aligned}$$

Sabemos que:

$$Var(X_i^2) = E(X_i^2) - E(X_i)^2 = Var(X_i) + E(X_i)^2 = \sigma^2 + \mu^2$$

E alem disso:

$$\begin{aligned} Var(\bar{X}) &= E\left(\bar{X}^2 \left\{E(\bar{X})^2\right\}\right) \\ E(\bar{X}^2) &= Var(\bar{X}) + \left\{E(\bar{X})^2\right\} \end{aligned}$$

$$\begin{aligned} Var(\bar{X}) &= Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n Var(X_i) = \frac{1}{n} \sigma^2 \\ &= \frac{\sigma^2}{n} \end{aligned}$$

$$\begin{aligned} E(\bar{X}^2) &= Var(\bar{X}) + \left\{E(\bar{X})^2\right\} \\ &= \frac{\sigma^2}{n} + \mu^2 \end{aligned}$$

Com isso, temos que:

$$\begin{aligned} E(\sigma^2) &= \frac{1}{n} \{\sigma^2 + \mu^2\} \\ &= \sigma^2 + \mu^2 - \left(\frac{\sigma^2}{n} + \mu^2\right) \\ &= \sigma^2 - \frac{\sigma^2}{n} \\ &= \frac{\sigma^2(n-1)}{n} \end{aligned}$$

Logo,

$$\beta_{\sigma^2}(\bar{\sigma}^2) = \frac{-\sigma^2}{n}$$

Portanto,  $\bar{\sigma}^2$  eh um estimador viciado. Por outro lado, temos:

$$\lim_{n \rightarrow \infty} \beta_{\sigma^2}(\sigma^2) = \lim_{n \rightarrow \infty} \left(\frac{-\sigma^2}{n}\right) = 0$$

E  $\tilde{\sigma}^2$  sera assistonticamente nao-viciado.

**Observacao** O calculo do vicio de um estimador pode ser usado para sugerir novos estimadores. Por exemplo, considere  $\tilde{\sigma}^2$  o estimador para  $\sigma^2$ , cujo vicio é  $\frac{-\sigma^2}{n}$ . Um novo estimador não-viciado pode ser obtido por:

$$\begin{aligned} E(\tilde{\sigma}^2) &= \frac{\sigma^2(n-1)}{n} \\ \frac{n}{n-1} E(\tilde{\sigma}^2) &= \sigma^2 \\ E\left(\frac{n\tilde{\sigma}^2}{n-1}\right) &= \sigma^2 \end{aligned}$$

Logo,  $S^2 = \frac{n\tilde{\sigma}^2}{n-1}$  é um estimador não-viciado para  $\sigma^2$ , pois  $E(S^2) = \sigma^2$ . Assim, o estimador não-viciado para  $\sigma^2$  é:

$$\begin{aligned} S^2 = \frac{n\tilde{\sigma}^2}{n-1} &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1} \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1} \end{aligned}$$

**Exemplo:** Considere uma amostra de tamanho  $n$  da v.a.  $X$  com distribuição  $N(\mu; \sigma^2)$ . Considere dois estimadores para  $\mu$ :

$$\begin{aligned} \tilde{\mu}_1 &= X_1 \\ \tilde{\mu}_2 &= \bar{X} \end{aligned}$$

- (a) Qual dos estimadores é melhor do ponto de vista de eficiência?
- (b) E do ponto de vista de consistência?

**Resposta** (a)

$$\begin{aligned} E(\tilde{\mu}_1) &= E(X_1) = \mu \\ E(\tilde{\mu}_2) &= E(\bar{X}) = E\left(\frac{\sum_{i=1}^n X_i}{n}\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \mu \end{aligned}$$

$$Var(\tilde{\mu}_1) = Var(X_1) = \sigma^2$$

$$Var(\tilde{\mu}_2) = Var(\bar{X}) = \frac{\sigma^2}{n}$$

Como  $Var(\tilde{\mu}_2) < Var(\tilde{\mu}_1)$ , temos que  $\tilde{\mu}_2$  é melhor.

(b) Avaliando a consistencia pela proposicao.

Para  $\tilde{\mu}_1$

$$\lim_{n \rightarrow \infty} E(\tilde{\mu}_1) = \lim_{n \rightarrow \infty} \mu = \mu$$

$$\lim_{n \rightarrow \infty} Var(\tilde{\mu}_1) = \lim_{n \rightarrow \infty} \sigma^2 = \sigma^2$$

Logo,  $\tilde{\mu}_1$  nao eh consistente.

Para  $\tilde{\mu}_2$

$$\lim_{n \rightarrow \infty} E(\tilde{\mu}_2) = \lim_{n \rightarrow \infty} \mu = \mu$$

$$\lim_{n \rightarrow \infty} Var(\tilde{\mu}_2) = \lim_{n \rightarrow \infty} \sigma^2 = 0$$

Logo,  $\tilde{\mu}_2$  eh consistente. Do ponto de vista de consistencia  $\tilde{\mu}_2$  eh melhor.

**Exemplo :**

Considere os estimadores  $\tilde{\sigma}^2$  e  $s^2$  para  $\sigma^2$ . Compare os seus EQM's e verifique se estes estimadores sao consistentes. Utilize o seguinte resultado:

$$Y = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{2} \tilde{X}_{(N+1)}^2$$

$$E(Y) = n - 1 \quad \text{e} \quad Var(y) = 2(n - 1)$$

$$\tilde{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})}{n}$$

$$s^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

$$EQM_{\sigma^2} = (T(X)) = Var(T(X)) + \{\beta_{\sigma^2}(T(x))\}^2$$

$$EQM_{\sigma^2}(\tilde{\sigma}^2) = Var(\tilde{\sigma}^2) + \{\beta_{\sigma^2}(\tilde{\sigma}^2)\}^2$$

Obtendo a  $Var\tilde{\sigma}^2$ :

$$\frac{1}{n}$$

$$\sigma^4 \frac{1}{n^2 Var\left(\frac{\sum_{i=1}^n}{\sigma^2}\right)} = \frac{\sigma^4}{n^2} 2(n-1)$$

$$Var(\tilde{\sigma}^2) = Var\left(\sum_{i=1}^n (X_i - \bar{X})^2\right)$$


---


$$n \frac{\sigma^4}{n^2} Var\left(\sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2}\right) = \frac{\sigma^4}{n^2} 2(n-1)$$

$$\begin{aligned} EQM_{\sigma^2}(\tilde{\sigma}^2) &= \frac{\sigma^4}{n^2} 2(n-1) + \left[-\frac{\sigma^2}{n}\right]^2 \\ &= \frac{\sigma^4}{n^2} 2(n-1) + \frac{\sigma^4}{n^2} \\ &= \frac{\sigma^4}{n^2} \{2n - 2 + 1\} \\ &= \frac{\sigma^4}{n^2} \{2n - 1\} \end{aligned}$$